

Splines con Penalizaciones: Teoría y aplicaciones

María Durbán ¹

Universidad Carlos III de Madrid

¹Con la colaboración de Dae-Jin Lee

Índice general

1.	Introducción	2
1.	Splines con penalizaciones (P-splines)	3
1.	Bases y Penalizaciones	3
1.1.	Bases y nodos	4
1.2.	Penalizaciones y coeficientes	8
1.3.	Estimación de parámetros y grados de libertad	11
1.4.	Selección del parámetro de suavizado	12
2.	P-splines Bayesianos	12
3.	P-splines como modelos mixtos	13
3.1.	Intervalos de confianza en modelos de suavizado	16
3.2.	Datos correlados	17
4.	Modelos para datos no Gaussianos	18
4.1.	GLMM para datos de Poisson	18
5.	P-splines para datos multidimensionales	19
5.1.	P-splines multidimensionales como modelos mixtos	20
2.	Software	23
3.	Aplicaciones	30
1.	Modelos Semiparamétricos	30
2.	Modelos Aditivos	34
3.	P-splines para datos longitudinales	36
3.1.	Modelo con ordenada en el origen aleatoria	37
3.2.	Modelo aditivo mixto	38
3.3.	Modelo con diferencias individuales lineales	40
3.4.	Interacción de curva por factor	42
3.5.	Curvas específicas para cada individuo	42
4.	Datos correlados	48
5.	Datos multidimensionales	50
5.1.	Ejemplo 1: Tendencias espaciales en experimentos de campo	50
5.2.	Ejemplo 2: Análisis de datos de mortalidad	51
5.3.	Ejemplo 3: Aplicaciones en disease mapping	55

1. Introducción

No hay duda de que las técnicas de suavizado tienen en la actualidad un papel muy relevante. Esta popularidad se debe en parte a la complejidad de los datos que se generan: imágenes, microarrays, etc., y que hacen que un modelo paramétrico sea inviable, además, los avances informáticos han reducido el coste computacional que supone utilizar los modelos de suavizado.

Muchas veces se utiliza el término “*no-paramétrico*” para referirse a estos modelos, pero este nombre es sólo adecuado si se utilizan modelos tipo kernel ya que el suavizado con splines se hace mediante parámetros.

Hay dos grandes enfoques en el tema de modelos de suavizado con splines: a) splines de suavizado (smoothing splines) y b) splines de regresión (regression splines). Los splines de suavizado (ver por ejemplo Green and Silverman (1994)) utilizan tantos parámetros como observaciones, lo que hace que su implementación no sea eficiente cuando el número de datos es muy elevado. Los splines de regresión pueden ser ajustados mediante mínimos cuadrados una vez que se han seleccionado el número de nodos, pero la selección de los nodos se hace mediante algoritmos bastante complicados.

Los splines con penalizaciones combinan lo mejor de ambos enfoques: utilizan menos parámetros que los splines de suavizado, pero la selección de los nodos no es tan determinante como en los splines de regresión. Hay tres razones fundamentales para el uso de este tipo de splines:

1. Son splines de rango bajo, es decir, que el tamaño de la base utilizada es mucho menor que la dimensión de los datos, al contrario de lo que ocurre en el caso de los splines de suavizado donde hay tantos nodos como datos, lo que hace que sea necesario trabajar con matrices de alta dimensión. El número de nodos, en el caso de los P-splines, no supera los 40, lo que hace que sean computacionalmente eficientes, sobre todo cuando se trabaja con gran cantidad de datos.
2. La introducción de penalizaciones relaja la importancia de la elección del número y la localización de los nodos, cuestión que es de gran importancia en los splines de rango bajo sin penalizaciones (ver por ejemplo Rice and Wu (2001)).
3. La correspondencia entre los P-splines y el BLUP en un modelo mixto permite, en algunos casos, utilizar la metodología existente en el campo de los modelos mixtos y el uso de software como PROC MIXED en SAS y `lme()` en S-PLUS y R.

Capítulo 1

Splines con penalizaciones (P-splines)

1. Bases y Penalizaciones

Supongamos que tenemos n pares de datos (x_i, y_i) y estamos interesados en ajustar el modelo

$$y_i = f(x_i) + \epsilon_i \quad \epsilon_i \sim N(0, \sigma^2)$$

donde $f(\cdot)$ es una función suave de los datos. Por ejemplo, simulamos los siguientes datos:

```
n = 200
x = seq(0,1,length=n)
y = sin(3*pi*x) + 0.5*rnorm(n)
plot(x,y,pch=1,bty="l",col=12)
lines(x,sin(3*pi*x),col=6)
```

Nuestro objetivo es estimar la función $f(x) = \sin(3\pi x)$ mediante splines con penalizaciones. Los P-splines fueron introducidos por Eilers and Marx (1996), aunque han alcanzado gran popularidad recientemente (ver por ejemplo Ruppert et al. (2003)). La metodología se puede resumir de la siguiente forma: (a) utilizar una base para la regresión, y (b) modificar la función de verosimilitud introduciendo una penalización basada en diferencias entre coeficientes adyacentes. En el caso de datos normalmente distribuidos tenemos el modelo de regresión $\mathbf{y} = \mathbf{B}\mathbf{a} + \boldsymbol{\epsilon}$, donde $\boldsymbol{\epsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$, y $\mathbf{B} = \mathbf{B}(\mathbf{x})$ es la base de regresión construida a partir de $\mathbf{x}$. Para estimar los coeficientes de regresión se minimiza la función de mínimos cuadrados penalizados:

$$S(\mathbf{a}; \mathbf{y}, \lambda) = (\mathbf{y} - \mathbf{B}\mathbf{a})'(\mathbf{y} - \mathbf{B}\mathbf{a}) + \lambda \mathbf{a}' \mathbf{P} \mathbf{a} \quad (1.1)$$

donde $\mathbf{P}$ es una matriz que penaliza los coeficientes de forma suave y λ es el parámetro de suavizado. Fijado un valor de λ , minimizar (1.1) da lugar al sistema de ecuaciones

$$(\mathbf{B}'\mathbf{B} + \lambda \mathbf{D}'\mathbf{D})\hat{\mathbf{a}} = \mathbf{B}'\mathbf{y}. \quad (1.2)$$

Si $\lambda = 0$ se corresponde con las ecuaciones normales de regresión de $\mathbf{y}$ sobre $\mathbf{B}$. Es importante el hecho de que el tamaño del sistema de ecuaciones anterior depende del tamaño de la base y no del número de observaciones.




Figura 1: Datos simulados, la línea corresponde a $f(x) = \sin(3\pi x)$

El parámetro λ determina la influencia de la penalización: si es 0, estamos en un caso de regresión con B-splines, y si λ es muy grande, estaríamos ajustando un polinomio de grado $p-1$.

Es sencillo probar que:

$$\hat{\mathbf{y}} = \mathbf{B}(\mathbf{B}'\mathbf{B} + \lambda\mathbf{D}'\mathbf{D})^{-1}\mathbf{B}'\mathbf{y} = \mathbf{H}\mathbf{y}, \quad (1.3)$$

$\mathbf{H}$ no es una matriz de proyección, ya que no es idempotente, pero su forma hace que el método de suavizado sea lineal. La traza de $\mathbf{H}$ corresponde a la dimensión del modelo (el número equivalente de parámetros que estaríamos estimando).

1.1. Bases y nodos

La base para la regresión se puede calcular de muchas maneras, y de hecho hay dos grandes grupos dentro de los estadísticos que utilizan los P-splines: los que utilizan las bases polinomios truncados y los que utilizan las bases de B-splines. Además existen otras alternativas como thin plate regression splines.

Polinomios truncados

Supongamos de nuevo que tenemos pares (x_i, y_i) , $i = 1, \dots, n$. Para simplificar, vamos a suponer que $\mathbf{x}$ está en $[0, 1]$. Tomamos k nodos equidistantes en ese intervalo $t_j = (j-1)/k$, $j = 2, \dots, k+1$. Una base de polinomios truncados de grado p viene dada por:

$$1, x, x^2, \dots, x^p, \{(x - t_1)_+\}^p, \dots, \{(x - t_k)_+\}^p$$

donde $x_+ = \max(0, x)$ (por eso son truncados, ya que a partir de un cierto punto valen 0). La función $\{(x - t)_+\}^p$ tienen $p - 1$ derivadas continuas, de modo que cuanto mayor sea p más suave son las funciones en la base. En lenguajes como Matlab, Splus o R es trivial el cálculo de estas funciones:

```
tpoly= function(x,t,p){
#Polinomios truncados de grado p
B=NULL
for(i in 1:length(t)){
B=cbind(B,(x-t[i])^p * (x>t[i]))
}
}
```

Tomamos los nodos, por ejemplo, si queremos 10 nodos:

```
K=10
knots=seq(0,1,length=(K+2))[-c(1,K+2)]
```

entonces,

```
B0=tpoly(x,knots,0)
B1=tpoly(x,knots,1)
B2=tpoly(x,knots,2)
B3=tpoly(x,knots,3)
```

son bases de polinomios truncados de grado 0, 1, 2 y 3 respectivamente (ver Figura 2)

B-splines

Las referencias básicas son De Boor (1977) y Dierckx (1993). Un B-spline está formado por trozos de polinomios conectados entre si. Un ejemplo muy simple aparece en la parte superior izquierda de la Figura 3: un B-spline de grado 1. Está formado por dos trozos de polinomio lineal que se unen en un nodo, en la parte derecha aparecen más B-splines, cada uno de los cuales está basado en tres nodos. En la parte inferior aparece un B-spline de grado tres, está formado por 4 trozos de polinomios unidos entre si, de nuevo vemos que todas las funciones de la base tienen la misma forma, pero están desplazadas horizontalmente (el desplazamiento es una función de la distancia entre los nodos). En general un B-spline de grado p :

- Consiste en $p + 1$ trozos de polinomio de orden p .
- Se unen en p nodos internos
- En los puntos de unión las derivadas hasta el orden $p - 1$ son continuas.
- El B-spline es positivo en el dominio expandido por $p + 2$ nodos y 0 en es resto.
- Excepto en los extremos, se solapa con $2p$ trozos de polinomios de sus vecinos.




Figura 2: Bases de polinimios truncados de grado 0, 1, 2 y 3

- Para cada valor de x , $p + 1$ B-splines son no nulos.

Los B-splines no “padecen” los efectos de frontera comunes en otros métodos de suavizado, como algunos kernels, en los que al extender la curva ajustada fuera del dominio de los datos ésta tiende hacia cero. De Boor (2001) presenta un algoritmo para el cálculo de los B-splines, este algoritmo se puede simplificar fácilmente en software como MATLAB, S-PLUS y R, por ejemplo, la función para el cálculo de una base de B-splines de orden $bdeg$ con ndx nodos sería:

```
bspline = function(x, xl, xr, ndx, bdeg){
  dx = (xr-xl)/ndx
  knots = seq(xl-bdeg*dx, xr+bdeg*dx, by=dx)
  B = spline.des(knots,x,bdeg+1,0*x)design
  B}
```




Figura 3: Bases de B-splines de orden 1 y 3.

Thin plate regression splines (tprs)

Los thin plate splines son funciones que minimizan la función objetivo:

$$\sum (y_i - f(x_i))^2 + \lambda \int \left(\frac{\partial^2 f}{\partial x^2} \right)^2 dx$$

Es posible reescribir la ecuación anterior como:

$$\|\mathbf{y} - \mathbf{E}\boldsymbol{\delta} - \mathbf{T}\boldsymbol{\gamma}\| + \lambda \boldsymbol{\delta}' \mathbf{E} \boldsymbol{\delta}$$

En Green and Silverman (1994) se pueden encontrar más detalles sobre este método de suavizado.

El principal problema es que el número de nodos (y por lo tanto el número de parámetros) es igual al número de datos, lo que hace que sea computacionalmente muy costoso, sobre todo cuando pasamos al caso multidimensional. Por ello, Wood (2003) desarrolló los *thin plate regression splines* que son una versión de los anteriores en la que el número de

nodos es mucho menor al número de datos. La Figura 4 muestra una base the thin plate regression splines.




Figura 4: Bases de thin plate regression splines.

1.2. Penalizaciones y coeficientes

Supongamos que tenemos una base $\mathbf{B}$ construida con k nodos. Si utilizamos mínimos cuadrados para ajustar el modelo, la función objetivo será:

$$S(\mathbf{a}; \mathbf{y}) = (\mathbf{y} - \mathbf{B}\mathbf{a})'(\mathbf{y} - \mathbf{B}\mathbf{a}) \Rightarrow \hat{\mathbf{a}} = (\mathbf{B}'\mathbf{B})^{-1}\mathbf{B}'\mathbf{y}$$

y la curva ajustada $\hat{f}(x) = \mathbf{B}\hat{\mathbf{a}}$ dependerá del tamaño de la base. En la Figura 5 vemos el efecto que tiene el tamaño de la base en la curva, cuanto mayor sea la base menos suave es la curva, cuando el número de nodos coincide con el número de datos obtenemos una curva que interpola los datos.

Para solucionar esta situación, O'Sullivan (1986) introdujo una penalización en la segunda derivada de la curva, de modo que la función objetivo pasó a ser:

$$S(\mathbf{a}; \mathbf{y}, \lambda) = (\mathbf{y} - \mathbf{B}\mathbf{a})'(\mathbf{y} - \mathbf{B}\mathbf{a}) + \lambda \int_{\mathbf{x}} (\mathbf{B}''\mathbf{a})^2 d\mathbf{x}$$

La integral de la segunda derivada de la curva ajustada al cuadrado es una penalización bastante común (es la que se utiliza en los splines de suavizado), sin embargo, no hay nada de particular en la segunda derivada, se puede utilizar derivadas de cualquier orden. La




Figura 5: Curva estimada con 3, 10 y 20 nodos.

novedad que introducen los P-splines es que la penalización es discreta y que se penalizan los coeficientes directamente, en vez de penalizar la curva, lo que reduce la dimensionalidad del problema.

El tipo de penalización dependerá del tipo de base que se esté utilizando. En el caso de polinomios truncados, se utiliza una penalización “ridge” independientemente del grado de los polinomios truncados, es decir:

$$S(\mathbf{a}; \mathbf{y}, \lambda) = (\mathbf{y} - \mathbf{B}\mathbf{a})'(\mathbf{y} - \mathbf{B}\mathbf{a}) + \lambda \mathbf{a}'\mathbf{a}$$

esto equivale a poner una penalización en la derivada $p + 1$ de la curva.

Por el contrario, Eilers and Marx (1996) utiliza una penalización basada en la diferencias de orden d entre los coeficientes adyacentes de la bases de B-splines, este tipo de penalización es más flexible ya que es independiente del grado del polinomio utilizado para construir los B-splines. Esta es una buena aproximación discreta a la integral de la d -ésima derivada al cuadrado. La penalización se añade a la función de mínimos cuadrados, dando lugar a una función de mínimos cuadrados penalizados,

$$S(\mathbf{a}; \mathbf{y}, \lambda) = (\mathbf{y} - \mathbf{B}\mathbf{a})'(\mathbf{y} - \mathbf{B}\mathbf{a}) + \lambda \mathbf{a}'\mathbf{P}_d\mathbf{a} \Rightarrow \hat{\mathbf{a}} = (\mathbf{B}'\mathbf{B} + \lambda\mathbf{P}_d)^{-1}\mathbf{B}'\mathbf{y} \quad (1.4)$$

donde $\mathbf{P}_d = (\Delta^d)' \Delta^d$, si $d = 0$ tenemos una penalización ridge. En general se utiliza $d = 2$, aunque se puede utilizar ordenes superiores o inferiores, dependiendo de la variabilidad de la curva y de la cantidad de ruido en los datos. Por ejemplo, una penalización de orden $d = 2$

equivale a

$$(a_1 - 2a_2 + a_3)^2 + \dots + (a_{k-2} - 2a_{k-1} + a_k)^2 = \mathbf{a}' \mathbf{D}' \mathbf{D} \mathbf{a}$$

donde

$$\mathbf{D} = \begin{bmatrix} 1 & -2 & 1 & 0 & \dots \\ 0 & 1 & -2 & 1 & \dots \\ 0 & 0 & 1 & -2 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

En el caso de thin plate regression splines, ya vimos anteriormente utilizan una penalización cuadrática que mide la complejidad de la curva y es una versión truncada de la penalización de un thin plate splines.

La Figura 6 se muestra el ajuste de una curva mediante B-splines sin y con penalización, se muestran las funciones que forman las bases (las columnas de la matriz $\mathbf{B}$) multiplicadas por los coeficientes, así como los coeficientes (en un círculo), en la parte izquierda vemos como el patrón errático de los coeficientes da lugar a una curva poco suave, en cambio en la parte derecha, cuando se les impone que se pase de un coeficiente a otro de forma suave, la




Figura 6: Curva estimada con 20 nodos, sin penalizar los coeficientes (izquierda) y penalizando los coeficientes (derecha).

curva tambien lo es. Este gráfico muestra lo que está haciendo la penalización: fuerza a los coeficientes a que sigan un patrón suave.

Entre las propiedades de los P-splines con bases de B-splines hay que destacar que no tienen efecto de frontera (como le ocurre a los kernels), el efecto de frontera es el que hace que al extender la curva fuera del dominio de $\mathbf{x}$ la curva caiga rápidamente hacia 0, esto no pasa con los P-splines. Además, los P-splines ajustan de forma exacta los polinomios, es decir, si la curva es polinómica, un P-spline la recuperará exactamente. Por último, se conservan los momentos, es decir, que la media y la varianza de los valores ajustados será la misma que la de los datos sea cual sea el parámetro de suavizado, al contrario que los kernels que tienden a aumentar la varianza cuanto mayor es el suavizado.

La selección y localización de los nodos no está hecha de antemano, como en el caso de los smoothing splines, si se elige un número suficientemente grande de nodos es suficiente con elegirlos de forma equidistante; aunque autores como Ruppert (2002) aconsejan elegir los nodos K nodos en los K -quantiles de $\mathbf{x}$, es decir que cada nodo t_k sería el cuantil $k/(K + 1)$ de $\mathbf{x}$. En cuanto al número de nodos, la mayoría de los autores utilizan como regla:

$$\text{número de nodos} = \min\{40, \text{valores únicos de } \mathbf{x}/4\}$$

1.3. Estimación de parámetros y grados de libertad

Hemos visto en la sección anterior, que dada una base $\mathbf{B}$ y una penalización $\mathbf{P}$, buscamos estimar un conjunto de parámetros $\mathbf{a}$ que optimiza la verosimilitud penalizada dada en (1.4), la solución es:

$$\hat{\mathbf{a}} = (\mathbf{B}'\mathbf{B} + \lambda\mathbf{P})^{-1}\mathbf{B}'\mathbf{y} \Rightarrow \hat{f}(x) = \mathbf{B}\hat{\mathbf{a}}$$

Es importante caer en la cuenta de que la ecuación anterior depende de λ , el parámetro de suavizado, el cual, por el momento vamos a suponer conocido (más adelante abordaremos el tema de la estimación de dicho parámetro).

El otro parámetro que queda por estimar es la varianza residual, σ^2 , la estimación de este parámetro depende de los grados de libertad del modelo, por lo que hemos de introducir el concepto de *grados de libertad efectivos*.

Grados de libertad efectivos

Si en un modelo con P-splines tomamos $\lambda = 0$, entonces los grados de libertad del modelo se corresponden con la dimensión de la base $\mathbf{B}$ menos el número de restricciones del modelo, por el contrario, si tomamos un valor grande de λ el modelo es muy poco flexible y tendrá muy pocos grados de libertad. Para definir los grados de libertad en este tipo de modelos, la opción más lógica es utilizar una definición análoga a la que se utiliza en los modelos de regresión paramétricos:

$$d.f. = \text{traza}(\mathbf{H}) \quad \text{donde} \quad \hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$$

En este caso:

$$\mathbf{H} = \mathbf{B}(\mathbf{B}'\mathbf{B} + \lambda\mathbf{P})^{-1}\mathbf{B}'$$

por lo que

$$d.f. = \text{traza}(\mathbf{H}) = \text{traza}(\mathbf{B}'\mathbf{B} + \lambda\mathbf{P})^{-1}\mathbf{B}'\mathbf{B}$$

y la traza de esa matriz variará dependiendo del parámetro de suavizado.

Estimación de la varianza residual

En el caso de errores gaussianos, nuevamente utilizamos la equivalencia con el caso de regresión lineal:

$$\hat{\sigma}^2 = \frac{\|\mathbf{y} - \mathbf{B}\mathbf{a}\|^2}{n - \text{traza}(\mathbf{H})},$$

aunque este estimador no es insesgado, ya que depende del sesgo introducido por el suavizado, es el que se utiliza normalmente.

1.4. Selección del parámetro de suavizado

El papel del parámetro de suavizado en los P-splines, es el mismo que tiene en cualquier otro método de suavizado: controlar la suavidad de la curva, pero aquí lo que hace es penalizar los coeficientes que están muy separados entre sí, y cuanto mayor sea λ , más se aproximarán los coeficientes a cero, de modo que si $\lambda \rightarrow \infty$ nos aproximamos a un ajuste polinómico. Por el contrario, cuando $\lambda \rightarrow 0$ estaremos utilizando mínimos cuadrados ordinarios.

Ahora, al igual que en otros métodos de suavizado, hemos de elegir un criterio para seleccionar el parámetro de suavizado, podemos utilizar AIC, GCV, BIC, etc. Por ejemplo:

$$GCV = \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{n - \text{traza}(\mathbf{H})}; \quad \mathbf{H} = \mathbf{B}(\mathbf{B}'\mathbf{B} + \lambda\mathbf{D}'\mathbf{D})^{-1}\mathbf{B}'$$

$$AIC = 2\log\left(\sum_{i=1}^n (y_i - \hat{y}_i)^2\right) - 2\log(n) + 2\log(\text{traza}(\mathbf{H}))$$

La ventaja de los P-splines es que es mucho más rápido calcular la traza de esa matriz que con otro tipo de suavizadores.

2. P-splines Bayesianos

Los P-splines Bayesianos (Lang and Brezger, 2004) son una extensión de los P-splines de Eilers and Marx (1996), en la que la penalización basada en diferencias se sustituye por su análogo estocástico: paseos aleatorios Gaussianos que sirven como distribuciones a-priori para los coeficientes. Una penalización basada en diferencias de orden 1 ó 2 corresponden a paseos aleatorios del mismo orden, si tenemos c coeficientes, a_j , correspondientes a una base de B-splines $\mathbf{B}$:

$$a_j = a_{j-1} + v_j \quad \text{ó} \quad a_j = 2a_{j-1} - a_{j-2} + v_j$$




Figura 7: Curvas ajustadas para distintos valores de λ .

donde $v_j \sim N(0\tau^2)$.

En este caso, la cantidad de suavizado es controlada por $\tau^2 = \sigma^2/\lambda$. En general, para una penalización $\mathbf{P}$ podemos escribir:

$$\mathbf{a}|\tau^2 \propto \exp\left(-\frac{1}{2\tau^2}\mathbf{a}'\mathbf{P}\mathbf{a}\right)$$

el rango de $\mathbf{P}$ es $c - 1$ para un paseo aleatorio de orden 1, y $m - 2$ para uno de orden 2, por lo tanto, tenemos una a-priori impropia.

Como hemos supuesto anteriormente que

$$\mathbf{y}|\mathbf{a} \sim N(\mathbf{B}\mathbf{a}, \mathbf{I}\sigma^2),$$

tenemos que

$$\mathbf{a}|\mathbf{y} \sim N(\hat{\mathbf{a}}, (\mathbf{B}'\mathbf{B} + \lambda\mathbf{P})^{-1}\sigma^2) \quad (1.5)$$

Esto nos va a permitir calcular intervalos de confianza para cualquier función lineal del vector de parámetros $\mathbf{a}$ (Wood, 2007). El software *BayesX* (Brezger et al., 2005) permite el ajuste de P-splines bayesianos.

3. P-splines como modelos mixtos

La gran revolución de los P-splines producida en los últimos años es debida a la posibilidad de escribir un modelo no-paramétrico o semiparamétrico donde se utilizan P-splines

como un modelo mixto (o modelo con efectos aleatorios), la ventaja que tiene el utilizar este enfoque es que nos permite: por un lado utilizar toda la metodología desarrollada para los modelos mixtos, y por otro, utilizar el software para modelos mixtos que está disponible en la mayoría de los programas estadísticos.

La conexión entre regresión no paramétrica y los modelos mixtos se remonta a principio de los 90 (Speed, 1991). Más tarde, otros autores como Verbyla et al. (1999) y Brumback and Rice (1998) desarrollan en más profundidad el tema del suavizado con modelos mixtos (en el contexto de los splines cúbicos) y más tarde (Wand, 2003) en el contexto de los P-splines con polinomios truncados como bases. Sin embargo, no se había intentado buscar una representación de los P-splines con B-splines como bases como modelos mixtos, lo cual, entre otras cosas daría lugar a bases más estables.

El interés por la representación de los P-splines como modelos mixtos surgió de las dificultades que surgen en el campo de los modelos aditivos de suavizado, ya que hay problemas de identificabilidad del modelo. El uso de los P-splines hace que no sea necesario un método iterativo (como el *backfitting algorithm*) para la estimación de las curvas, pero era entonces necesario modificar las bases de forma que una curva se pueda descomponer como suma de un componente polinómico (del mismo orden que la penalización) y otro no polinómico, es decir, dado el modelo:

$$\begin{aligned} \mathbf{y} &= \mathbf{B}\mathbf{a} + \boldsymbol{\epsilon} \quad \boldsymbol{\epsilon} \sim N(0, \sigma^2 \mathbf{I}) \quad \text{lo reformulamos como} \\ \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon} \quad \boldsymbol{\epsilon} \sim N(0, \sigma^2 \mathbf{I}) \end{aligned}$$

Según la base que haya utilizado para los P-splines, $\mathbf{X}$ y $\mathbf{Z}$ tendrán una forma diferente:

- **Polinomios truncados**

$$\mathbf{X} = [\mathbf{1}, \mathbf{x}, \dots, \mathbf{x}^p] \quad \mathbf{Z} = [(x_i - \kappa_k)_+^p,] \quad 1 \leq i \leq n, 1 \leq k \leq \kappa$$

- **B-splines**

$$\mathbf{X} = [\mathbf{1} : \mathbf{x}] \quad \mathbf{Z} = \mathbf{B}\mathbf{U}\boldsymbol{\Sigma}^{-1/2}$$

donde $\mathbf{U}$ y $\boldsymbol{\Sigma}$ son matrices que forman parte de la descomposición en valores singulares de la matriz de penalización $\mathbf{D}'\mathbf{D}$.

Una vez descrita esta nueva base, es inmediato establecer la conexión con un modelo mixto, donde:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon} \quad \mathbf{u} \sim N(0, \sigma_u^2 \mathbf{I}_{c-2}) \quad \boldsymbol{\epsilon} \sim N(0, \sigma^2 \mathbf{I}), \quad (1.6)$$

donde c el número de columnas de la base original $\mathbf{B}$, y el parámetro de suavizado es $\lambda = \sigma^2/\sigma_u^2$, lo cual hace que sea posible estimar el parámetro de suavizado junto con los otros parámetros del modelo.

Uno de los conjuntos de datos con los que vamos a trabajar en el curso está basado en un estudio llevado a cabo en la Universidad de Harvard con niñas afectadas por leucemia linfoblástica aguda (los datos han sido modificados por cuestiones de confidencialidad). La

obesidad y la corta estatura son efectos comunes en los adolescentes que padecen o han padecido esta enfermedad y los tratamientos que se aplican intentan reducir al máximo este tipo de efectos secundarios sin comprometer su eficacia. En uno de los ensayos clínicos llevados a cabo se estudiaron 618 niños entre los años 1987 y 1995 y se aplicaron tres terapias distintas: terapia intracraneal sin radiación, terapia intracraneal con radiación convencional y terapia intracraneal con radiación dos veces al día. Se midió la altura de los niños aproximadamente cada 6 meses.

Para cada niño, la altura aumenta de forma suave a lo largo de los años, de modo que el modelo anterior sería apropiado para este tipo de datos.




Figura 8: Curva estimada para la altura de una niña en distintos instantes.

La Figura 8 muestra como la curva ajustada se descompone en una línea recta (si utilizamos una penalización de orden dos, o polinomios truncados de orden uno), más una parte que no es lineal, en el contexto de los modelos mixtos esto correspondería al efecto aleatorio.

En el contexto de los modelos mixtos, el método estándar para la estimación de los parámetros de la varianza es el método de máxima verosimilitud restringida (REML).

$$\ell_R(\sigma_u^2, \sigma_\varepsilon^2) = -\frac{1}{2} \log |\mathbf{V}| - \frac{1}{2} \log |\mathbf{X}'\mathbf{V}^{-1}\mathbf{X}| - \frac{1}{2} \mathbf{y}'(\mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1})\mathbf{y}, \quad (1.7)$$

donde $\mathbf{V} = \sigma_u^2 \mathbf{Z} \mathbf{Z}' + \sigma^2 \mathbf{I}$. El vector de parámetros $\boldsymbol{\beta}$ y el vector de coeficientes aleatorios $\mathbf{u}$ son estimados como:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}' \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{X}' \hat{\mathbf{V}}^{-1} \mathbf{y} \quad (1.8)$$

$$\hat{\mathbf{u}} = \hat{\sigma}_u^2 \mathbf{Z}' \hat{\mathbf{V}}^{-1} (\mathbf{y} - \mathbf{X} \hat{\boldsymbol{\beta}}) \quad (1.9)$$

$$\mathbf{V}^{-1} = \frac{1}{\sigma^2} (\mathbf{I} - \mathbf{Z} (\mathbf{Z}' \mathbf{Z} + (\sigma^2/\sigma_u^2) \mathbf{I}_{c-2})^{-1} \mathbf{Z}') \quad (1.10)$$

3.1. Intervalos de confianza en modelos de suavizado

Normalmente, en este tipo de modelos, estamos interesados en las curvas ajustadas, $\hat{f}(\mathbf{x}) = \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{Z} \hat{\mathbf{u}}$. La variabilidad de la curva estimada dependerá de si se tiene en cuenta o no la naturaleza aleatoria de $\mathbf{u}$. Por un lado, podemos argumentar que en la formulación de los P-splines como modelos mixtos, $\mathbf{u}$ es sólo una herramienta para modelar la curvatura, mientras que $\boldsymbol{\epsilon}$ tiene en cuenta la variabilidad alrededor de la curva. Si utilizamos este argumento, el cálculo de la varianza debe ser hecho con respecto a la distribución condicionada $\mathbf{y}|\mathbf{u}$,

$$Var[\hat{f}(\mathbf{x})|\mathbf{u}] = [\mathbf{X} : \mathbf{Z}] Cov \left(\begin{bmatrix} \hat{\boldsymbol{\beta}} \\ \hat{\mathbf{u}} \end{bmatrix} \middle| \mathbf{u} \right) [\mathbf{X} : \mathbf{Z}]'.$$

De (1.8) y (1.9), y la relación entre $[\mathbf{X} : \mathbf{Z}]$, la matriz de penalización $\mathbf{D}'\mathbf{D}$, y la matriz de B-splines $\mathbf{B}$, se deduce fácilmente que,

$$Var[\hat{f}(\mathbf{x})|\mathbf{u}] = \hat{\sigma}^2 \mathbf{B} (\mathbf{B}'\mathbf{B} + (\hat{\sigma}^2/\hat{\sigma}_u^2) \mathbf{D}'\mathbf{D})^{-1} \underbrace{\mathbf{B}' \mathbf{B} (\mathbf{B}'\mathbf{B} + (\hat{\sigma}^2/\hat{\sigma}_u^2) \mathbf{D}'\mathbf{D})^{-1} \mathbf{B}'}_{\mathbf{H}} \quad (1.11)$$

La matriz $\mathbf{H}$ se corresponde con la matriz del modelo (1.3), y los intervalos de confianza a los que da lugar se corresponden con los dados por Hastie and Tibshirani (1986).

El problema es que si existe sesgo, es decir, si $E[\hat{f}(\mathbf{x})|\mathbf{u}] \neq f(\mathbf{x})$ estos intervalos pueden ser insatisfactorios. Sin embargo, en el contexto de los modelos mixtos, es posible tener en cuenta el sesgo, para ello utilizamos $Var[(\hat{f}(\mathbf{x}) - f(\mathbf{x}))^2]$ (ver detalles en Ruppert et al., 2003),

$$Var[(\hat{f}(\mathbf{x}) - f(\mathbf{x}))^2] = \hat{\sigma}^2 \mathbf{B} (\mathbf{B}'\mathbf{B} + (\hat{\sigma}^2/\hat{\sigma}_u^2) \mathbf{D}'\mathbf{D})^{-1} \mathbf{B}', \quad (1.12)$$

o equivalentemente

$$Var[(\hat{f}(\mathbf{x}) - f(\mathbf{x}))^2] = \hat{\sigma}^2 \mathbf{C} (\mathbf{C}'\mathbf{C} + (\hat{\sigma}^2/\hat{\sigma}_u^2) \boldsymbol{\Lambda})^{-1} \mathbf{C}', \quad (1.13)$$

donde

$$\mathbf{C} = [\mathbf{X} : \mathbf{Z}] \quad \boldsymbol{\Lambda} = \begin{pmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \sigma^2/\sigma_u^2 \mathbf{I} \end{pmatrix}$$

lo cual da lugar a los correspondientes intervalos de confianza, y que son más anchos que los dados por (1.11), ya que tienen en cuenta ambos componentes del error (la varianza y el sesgo al cuadrado). Estos intervalos de confianza coinciden con los propuestos por Wahba (1983) y Nychka (1988). Estos autores sugieren un enfoque bayesiano similar al presentado anteriormente, de la ecuacion (1.5) podemos deducir de forma inmediata que la varianza de la curva ajustada $\hat{f}(\mathbf{x}) = \mathbf{B} \hat{\mathbf{a}}$ viene dada por (1.12).

3.2. Datos correlados

En el caso de datos correlados, si intentamos ajustar una curva sin tener en cuenta la correlación que hay en los datos, veremos que los métodos de selección del parámetro de suavizado van a elegir un valor del parámetro menor al que corresponde y por lo tanto la curva no va a ser suave. Si quisiéramos estimar tanto el parámetro de suavizado como los parámetros que determinan la estructura de correlación, necesitaríamos hacerlo de forma iterativa, lo que haría que el resultado final fuera muy sensible a la elección de los parámetros iniciales.

Sin embargo, con los P-splines como modelos mixtos es inmediato el introducir una estructura de correlación y estimarla simultáneamente a la curva suave. El modelo seguiría siendo el mismo:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon} \quad \mathbf{u} \sim N(0, \sigma_u^2 \mathbf{I}_{c-2}) \quad \boldsymbol{\epsilon} \sim N(0, \sigma^2 \boldsymbol{\Sigma}),$$

donde $\boldsymbol{\Sigma}$ representa la correlación entre los datos, y la matriz $\mathbf{V} = \sigma_u^2 \mathbf{Z}\mathbf{Z}' + \sigma^2 \boldsymbol{\Sigma}$.

La Figura 9 muestra datos de temperatura de Nueva York tomados en 111 días consec-




Figura 9: Curvas estimadas para los datos de temperatura

utivos, la curva negra corresponde a la estimación ignorando la estructura de correlación en los datos y la verde se obtiene asumiendo un proceso AR(1).

4. Modelos para datos no Gaussianos

Las ideas expuestas en las secciones anteriores se pueden aplicar al caso de modelos lineales generalizados con penalizaciones. Estos modelos fueron introducidos por Marx and Eilers (1998), en el caso unidimensional, y por Durbán et al. (2002) y Currie et al. (2004), en el caso bidimensional.

Sea $\boldsymbol{\mu} = E[\boldsymbol{\eta}]$, y suponemos que existe una función $g()$ tal que $\boldsymbol{\eta} = g(\boldsymbol{\mu}) = \mathbf{B}\mathbf{a}$. Minimizar la verosimilitud penalizada

$$\ell_p(\mathbf{a}) = \ell(\mathbf{a}) - \frac{1}{2}\lambda\mathbf{a}'\mathbf{D}'\mathbf{D}\mathbf{a}, \quad (1.14)$$

donde $\ell(\mathbf{a})$ es la verosimilitud ordinaria, da lugar a la versión penalizada del “*scoring algorithm*”:

$$(\mathbf{B}'\tilde{\mathbf{W}}_\delta\mathbf{B} + \lambda\mathbf{D}'\mathbf{D})\hat{\mathbf{a}} = \mathbf{B}'\tilde{\mathbf{W}}_\delta\mathbf{B}\tilde{\mathbf{a}} + \mathbf{B}'(\mathbf{y} - \tilde{\boldsymbol{\mu}}). \quad (1.15)$$

Aquí la matriz $\mathbf{W}_\delta$ es diagonal con elementos $w_{ii}^{-1} = (\partial\eta_i/\partial\mu_i)^2\text{var}(y_i)$, el símbolo $\tilde{}$ representa una solución aproximada, y $\hat{}$ representa la mejora de la aproximación.

Si los modelos con penalizaciones admiten una representación como modelos mixtos, la extensión natural serán los modelos lineales mixtos generalizados (GLMM). Coull et al. (2001) y Parise et al. (2001) entre otros, han mostrado cómo los P-splines con polinomios truncados como bases se pueden utilizar en este contexto y cómo usar el macro `glmmix` en SAS para ajustar dichos modelos. Vamos a ver el caso concreto de GLMM para datos de Poisson, la metodología sería similar para otras distribuciones.

4.1. GLMM para datos de Poisson

Los GLMM para las familias exponenciales con un solo parámetro (Poisson, logística, etc.), y función “*link*” canónica tienen la siguiente forma:

$$f(\mathbf{y}|\boldsymbol{\eta}) = \exp\{\mathbf{y}'\boldsymbol{\eta} - \mathbf{1}'b(\boldsymbol{\eta}) + \mathbf{1}'c(\mathbf{y})\} \quad (1.16)$$

en el caso de los P-splines, el predictor lineal $\boldsymbol{\eta} = \mathbf{B}\mathbf{a}$. Utilizando la representación de los P-splines como modelos mixtos, reescribimos $\mathbf{B}\mathbf{a} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha}$, entonces la ecuación anterior pasa a ser,

$$f(\mathbf{y}|\boldsymbol{\alpha}) = \exp\{\mathbf{y}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha}) - \mathbf{1}'\exp(\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha}) - \mathbf{1}'\log(\Gamma(\mathbf{y} + \mathbf{1}))\} \quad (1.17)$$

y $\boldsymbol{\alpha} \sim N(\mathbf{0}, \sigma_\alpha^2 \mathbf{I}_{c-2})$ donde c es el rango de $\mathbf{B}$.

Utilizamos la cuasi-verosimilitud penalizada de Breslow and Clayton (1993), lo cual nos lleva a las ecuaciones

$$\begin{aligned} \mathbf{X}'(\mathbf{y} - \exp(\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha})) &= \mathbf{0} \\ \mathbf{Z}'(\mathbf{y} - \exp(\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha})) &= \frac{\boldsymbol{\alpha}}{\sigma_\alpha^2}, \end{aligned}$$

que se resuelven mediante el “*scoring algorithm*” de Fisher con “*working vector*” $\mathbf{y} = \boldsymbol{\eta} + (\mathbf{y} - \boldsymbol{\mu})\frac{1}{\boldsymbol{\mu}}$, lo que da lugar a

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}\mathbf{y} \quad (1.18)$$

$$\hat{\boldsymbol{\alpha}} = \sigma_{\alpha}^2\mathbf{Z}'\mathbf{V}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \quad (1.19)$$

$$\mathbf{V} = \mathbf{W}^{-1} + \mathbf{Z}\mathbf{Z}'\sigma_{\alpha}^2.$$

con $\mathbf{W} = \text{diag}(\exp(\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha}))$. Entonces, condicionado a los estimadores obtenidos arriba, utilizamos REML para estimar los componentes de la varianza,

$$ql(\hat{\boldsymbol{\beta}}(\sigma_{\alpha}^2), \sigma_{\alpha}^2) \approx -\frac{1}{2}|\mathbf{V}| - \frac{1}{2}|\mathbf{X}'\mathbf{V}^{-1}\mathbf{X}| - \frac{1}{2}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{Z}\boldsymbol{\alpha})\mathbf{V}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{Z}\boldsymbol{\alpha})', \quad (1.20)$$

e iteramos entre (1.18), (1.19) y (1.20) hasta que haya convergencia.

5. P-splines para datos multidimensionales

Los modelos aditivos (Hastie and Tibshirani, 1987) son una clase importante dentro de los modelos multidimensionales. En 2 dimensiones, el modelo aditivo de suavizado sería $\mathbf{y} = f(\mathbf{x}_1) + f(\mathbf{x}_2) + \boldsymbol{\epsilon}$, donde $\mathbf{x}_1$ y $\mathbf{x}_2$ son variables explicativas. Una de las razones por las que este enfoque es tan popular es porque la hipótesis de aditividad controla los posibles problemas computacionales que surgen a la hora de estimar las curvas. Sin embargo, esta hipótesis es demasiado restrictiva cuando, por ejemplo, los datos están situados en un array y en vez de un modelo aditivo necesitamos suavizar los datos mediante un superficie no aditiva. En este contexto se han desarrollado varios enfoques: los basados en thin plate splines (ver, por ejemplo, Green and Silverman, 1994, o más tarde Wood, 2003), o, dentro del campo de los P-splines como modelos mixtos, los que utilizan bases radiales (Wand, 2003): en el primer caso, el problema que presentan es de tipo computacional, dado el tamaño de las bases y la dificultad para seleccionar el parámetro de suavizado, además es un método de suavizado isotrópico, apropiado en el caso de datos espaciales, pero no cuando las variables explicativas están medidas en diferentes unidades; en el caso de bases radiales, aunque los problemas computacionales son menores, el modelo también es isotrópico. Como alternativa, Durbán et al. (2002) propuso el uso del producto tensorial de B-splines como bases para el suavizado en dos o más dimensiones.

Supongamos que tenemos datos y_{ij} , $i = 1, \dots, n_1$, $j = 1, \dots, n_2$, organizados en un array con n_1 filas y n_2 columnas, y dos variables explicativas, $\mathbf{x}'_1 = (x_{11}, \dots, x_{1n_1})$ y $\mathbf{x}'_2 = (x_{21}, \dots, x_{2n_2})$. Sea $\mathbf{B}_1$ una matriz $n_1 \times c_1$ de B-splines para el suavizado a lo largo de $\mathbf{x}_1$, y $\mathbf{B}_2$ una matriz $n_2 \times c_2$ de B-splines para el suavizado a lo largo de $\mathbf{x}_2$. Entonces definimos la matriz de bases en 2 dimensiones como su producto tensorial,

$$\mathbf{B} = \mathbf{B}_2 \otimes \mathbf{B}_1 \quad (1.21)$$

La Figura 10 muestra un gráfico análogo a la Figura 3, pero en el caso bidimensional.




Figura 10: Base de B-splines en dos dimensiones.

El modelo a ajustar ahora es $\mathbf{y} = f(\mathbf{x}_1, \mathbf{x}_2) + \epsilon$, donde $\mathbf{y}$ es un vector de longitud $n_1 n_2$; de nuevo $E[\mathbf{y}] = \mathbf{B}\mathbf{a}$, o escrito en forma matricial, $E[\mathbf{Y}] = \mathbf{B}_1 \mathbf{A} \mathbf{B}_2$, donde $\mathbf{A}$ es una matriz $c_1 \times c_2$ que contiene a los coeficientes $\mathbf{a}$. De esta representación matricial del modelo surgió la idea de penalizar las filas y columnas de la matriz $\mathbf{A}$. La penalización de las filas viene dada por $\mathbf{a}'(\mathbf{I}_{c_2} \otimes \mathbf{D}_1' \mathbf{D}_1) \mathbf{a}$ y la de las columnas, $\mathbf{a}'(\mathbf{D}_2' \mathbf{D}_2 \otimes \mathbf{I}_{c_1}) \mathbf{a}$, con lo cual la matriz de penalizaciones viene dada por:

$$\mathbf{P} = \lambda_1 \mathbf{I}_{c_2} \otimes \mathbf{D}_1' \mathbf{D}_1 + \lambda_2 \mathbf{D}_2' \mathbf{D}_2 \otimes \mathbf{I}_{c_1}, \quad (1.22)$$

λ_1 y λ_2 son generalmente diferentes, lo que hace que el modelo sea no-isotrópico, lo que permite la posibilidad de que el suavizado sea mayor en una dimensión que en la otra (detalles y ejemplos en Durbán et al., 2002 y Currie et al., 2004).

5.1. P-splines multidimensionales como modelos mixtos

Hasta el momento, no existía una representación de modelos de suavizado no-isotrópicos en dos o más dimensiones como modelos mixtos. El objetivo es encontrar una representación similar a la dada en el caso de los datos unidimensionales. El hecho de que el modelo sea no-isotrópico, es decir, el utilizar el tipo de penalización que se propone en (1.22) puede, en un principio, dificultar la búsqueda de una nueva base que permita establecer la equivalencia entre modelos mixtos y P-splines con el producto tensorial de B-splines. Sin embargo, Currie et al. (2006) se muestra cómo en el caso de dos dimensiones o más, también existe una representación como modelo mixto que viene dada por:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha} \quad \boldsymbol{\alpha} \sim N(\mathbf{0}, \mathbf{G}) \quad \epsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}), \quad (1.23)$$

donde

$$\begin{aligned} \mathbf{X} &= \mathbf{X}_2 \otimes \mathbf{X}_1 = [\mathbf{1} : \mathbf{x}_2] \otimes [\mathbf{1} : \mathbf{x}_1] \\ \mathbf{Z} &= (\mathbf{Z}_2 \otimes \mathbf{X}_1 : \mathbf{X}_2 \otimes \mathbf{Z}_1 : \mathbf{Z}_2 \otimes \mathbf{Z}_1). \\ \mathbf{G} &= \sigma^2 \begin{pmatrix} \lambda_2 \boldsymbol{\Sigma}_{2s} \otimes \mathbf{I}_{q_1} & & \\ & \lambda_1 \mathbf{I}_{q_2} \otimes \boldsymbol{\Sigma}_{1s} & \\ & & \lambda_1 \mathbf{I}_{c_2-q_2} \otimes \boldsymbol{\Sigma}_{1s} + \lambda_2 \boldsymbol{\Sigma}_{2s} \otimes \mathbf{I}_{c_1-q_1} \end{pmatrix}^{-1} \end{aligned}$$

Los resultados que se presentan aquí, se extienden de forma inmediata a tres o más dimensiones, utilizando el producto de kronecker para la base, y añadiendo más términos a la penalización

Además, esta descomposición de la base, hace que de forma sencilla se puedan ajustar modelos del tipo: $\mathbf{y} = f(\mathbf{x}_1) + f(\mathbf{x}_2) + f(\mathbf{x}_1, \mathbf{x}_2) + \epsilon$. Aunque los resultados aquí presentado son para datos que están en un enrejado, se pueden aplicar al caso de datos dispersos como veremos en algunos ejemplos más adelante, la única diferencia es que el producto de kronecker de las bases se sustituye por el producto tensorial de las mismas.

Wood (2007) propone el uso de producto tensorial de bases de thin plate regression splines con penalizaciones similares a la la dada en (1.22). En el caso de P-splines bayesianos, se utilizaría un paseo aleatorio bivalente (se pueden ver más detalles en Kneib (2005)).

A modo de ilustración, veamos un ejemplo en el que los datos que provienen de un ensayo de campo llevado a cabo con cereales en el Scottish Crop Research Institute (SCRI, Reino Unido) con el objetivo de estudiar las tendencias espaciales que aparecen en los cultivos debido a la situación de los mismos. Los datos contenían información sobre la producción de grano de cada parcela y la posición de las parcelas en el campo

En la Figura vemos a la izquierda el ajuste de un modelo aditivo y a la derecha el modelo con interacción.



Figura 11: Vista de los cultivos en SCRI, Dundee, Reino Unido




Figura 12: Superficies ajustadas para los datos del SCRI.

Se aprecia claramente que los ajustes son distintos y que en el primer caso, el modelo aditivo impone una estructura muy restrictiva a la superficie ajustada. Una manera gráfica de comprobar el ajuste del modelo aditivo es hacer un gráfico de los residuos respecto de la posición en las filas, para cada una de las columnas; en la siguiente figura podemos observar como hay una tendencia no explicada en los residuos que se va modificando a lo largo de las columnas.




Figura 13: Gráfico de residuos del modelo aditivo.

Capítulo 2

Software

Nos vamos a centrar en el uso de R. Dado que se puede ver un modelo con P-splines como un modelo mixto, lo más inmediato es utilizar la función `lme()` para ajustar este tipo de modelos, esta función permite incluir efectos aleatorios, estructuras de covarianza y correlación, permite ajustar modelos aditivos, analizar datos longitudinales, etc. Sin embargo, el uso de estas funciones puede ser menos atractivo para el usuario no experto, ya que implica la creación de todas las matrices que intervienen en el modelo, aunque permite ver de forma clara lo que está haciendo el programa. Además, se han escrito paquetes en R: `mgcv` y `SemiPar`, que permiten ajustar este tipo de modelos, todos ellos están basados en las funciones `lme()` y `glmmPQL()` (para el caso de datos que no son normales). Además veremos funciones escritas específicamente para el caso de suavizado multidimensional. La idea es que os familiaricéis con todas las herramientas disponibles para que podáis elegir aquella que os sea más útil en cada caso.

La función `lme`

Para utilizar esta función es necesario cargar el paquete `nlme`.

La función admite que tanto la parte fija como la aleatoria se especifiquen mediante matrices, lo que hace que simplemente construyendo las matrices $\mathbf{X}$ y $\mathbf{Z}$ tal y como indicamos antes, podamos ajustar el modelo. El fichero `MMbasis.R` contiene dos funciones:

- `mixed.model.B` para el caso de B-splines.
- `mixed.model.T` para el caso de polinomios truncados.

```
library(splines)
library(nlme)
girl=read.table("girl.txt",header=TRUE)
y=girl$height
x=girl$age
source("MMbasis.R")

#Con B-splines
```


R Help on 'lme'

lme

package:nlme

R Documentation

Linear Mixed-Effects Models

Description:

This generic function fits a linear mixed-effects model in the formulation described in Laird and Ware (1982) but allowing for nested random effects. The within-group errors are allowed to be correlated and/or have unequal variances.

Usage:

```
lme(fixed, data, random, correlation, weights, subset, method,
    na.action, control, contrasts = NULL)
## S3 method for class 'lme':
update(object, fixed., ..., evaluate = TRUE)
```

```
MM=mixed.model.B(x,min(x)-0.5,max(x)+0.5,5,3,2)
```

```
X=MM[[1]]
```

```
Z=MM[[2]]
```

```
#Con polinomios truncados
```

```
MM=mixed.model.T(x,5,2)
```

```
X=MM[[1]]
```

```
Z=MM[[2]]
```

Una vez contruidas las matrices, hemos de darle a la función `lme()` la información necesaria para que ajuste la curva como el resultado de un modelo mixto:

```
n = length(y)
```

```
Id = factor(rep(1,length(y)))
```

```
#Que Id sea un vector de unos significa que no hay datos anidados
```

```
Z.block=list(list(Id=pdIdent(~Z-1)))
```

```
#pdIdent indica que la estructura de covarianza de la parte aleatoria
```

```
# es múltiplo de la identidad
```

```
Z.block=unlist(Z.block,recursive=FALSE)
```

```
data.fr = groupedData( y ~ X[,-1] | Id,data = data.frame(y,X,Z))
```

```
#es necesario crear esta estructura ya que estamos trabajando con matrices,
```

```
#no con variables
```

```
fit = lme(y~X[,-1],data=data.fr,random=Z.block)
```

¿Qué información podemos obtener de `fit`?:

- $\hat{\sigma}^2$:
`sigma.2 = fit$sigma^2`
- $\hat{\sigma}_u^2$
`sigma.2.alpha = sigma.2*exp(2*unlist(fit$modelStruct))`
- *REML*
`REML = fit$logLik`
- $\hat{\beta}$
`beta.hat = fit$coeff$fixed`
- $\hat{u}$
`alpha.hat = unlist(fit$coeff$random)`
- $\hat{f}$
`f.hat=c(X%%beta.hat+Z%%alpha.hat[1:ncol(Z)])`
`#o`
`d = ncol(fit$fitted)`
`f.hat = fit$fitted[,d]`
- Intervalo de confianza para $\hat{f}$
`IC=Int.Conf(X,Z,f.hat,sigma.2,sigma.2.alpha)`

El resultado es aparece en la Figura 1.

La función `spm()`

Para utilizar esta función es necesario cargar el paquete **SemiPar** que está basado en el libro *Semiparametric Regression* de Ruppert et al. (2003)).

La función `spm()` es similar a la función `gam()`, con la ventaja de que el parámetro de suavizado se puede especificar o elegir mediante REML. La base que utiliza por defecto, son los splines cúbicos, sin embargo, es posible utilizar polinomios truncados, eligiendo el grado del polinomio y/o los nodos.

```
library(SemiPar)
girl=read.table("girl.txt",header=TRUE)
y=girl$height
x=girl$age
fit = spm(y~f(x,basis="trunc.poly",degree=3))
```

El resultado de la función `spm` es una lista con tres componentes:




Figura 1: Curva estimada para la altura de una niña a distintas edades e intervalo de confianza.


1. `fit`:
que contiene la misma información que se obtiene de la función `lme()`.
2. `info`:
Contiene información sobre el modelo, las bases, los nodos, el grado del polinomio, etc.
3. `aux`:
Contiene las matrices de covarianza de los efectos fijo y aleatorios (`$cov.mat`), la varianza estimada de los efectos aleatorios, σ_u^2 (`$random.var`) y la residual, σ^2 (`$error.var`); así como los grados de libertad (aproximados) de cada componente (`$cdf`).

Se pueden encontrar más detalles en Ngo and Wand (2004).

```
plot(fit,shade=FALSE,se.lwd=1,se.col=3)
points(x,y)
```

da lugar a la figura que aparece en la página siguiente.

Un inconveniente de esta función, es que permite dibujar los intervalos de confianza, pero no da la opción de obtener los valores numéricos que constituyen esos intervalos de confianza.



La función gamm

Para utilizar esta función es necesario cargar el paquete `mgcv` de Wood (2006). En realidad, este paquete contiene dos funciones que permiten utilizar P-splines: `gam` y `gamm`, la diferencia entre las dos es que la segunda permite elegir el parámetro de suavizado mediante REML, mientras que la primera es similar a la función escrita por Hastie y Tibshirani, pero permite utilizar splines de rango bajo, además de haber corregido los errores que existían en el cálculo de la varianza de los parámetros y elige el parámetro de suavizado mediante GCV. En ambos casos podemos imponer un cierto parámetro de suavizado sin que sea elegido por la propia función.

La base que utiliza por defecto, son los thin plate regression splines, sin embargo, es posible utilizar otras bases como splines cúbicos, o B-splines y se puede elegir el número de nodos y el orden de la penalización. Los argumentos principales de esta función son los siguientes:

```
gamm(formula, random=NULL, correlation=NULL, family=gaussian())
```

Los dos primeros son similares a los de la función `lme`, aunque la fórmula permite especificar la parte no-paramétrica del modelo de forma más sencilla. Esta función permite incluir estructuras de correlación en el modelo, además de distribuciones no Gaussianas.

Para especificar los términos de suavizado se utiliza la función `s()`, sus argumentos son:

- **k**= Tamaño de la base, nunca debe ser menor que el orden de la penalización.
- **fx**= indica si estamos utilizando un spline de regresión con grados de libertad fijos (TRUE), o si estamos utilizando P-splines (FALSE)
- **bs**= Tipo de base que estamos utilizando, tiene las siguientes opciones:

- **cr**: cubic regression splines
- **cc**: periodic splines
- **tp**: thin plate regression splines
- **ps**: P-splines con bases de B-splines

m= orden de la penalización **by**= permite multiplicar curvas por factores

El resultado de la función **gamm** tiene dos componentes: **\$lme** y **\$gam**, cada uno de ellos contiene los objetos propios de cada una de esas dos funciones.

```
library(mgcv)
girl=read.table("girl.txt",header=TRUE)
y=girl$height
x=girl$age


fit = gam(y~s(x,k=5,m=2)) # elige el parámetro de suavizado con GCV
fit1 = gamm(y~s(x)) # elige el parámetro de suavizado con REML
fit1$lme
?gamm
?gam
fit1$gam
fit1$gam$sp
[1] 0.001957235
fit$sp
[1] 0.0003579374
```

Si queremos utilizar bases de B-splines necesitamos ejecutar primero el programa **bspline.R**. Este programa contiene funciones que nos permitirán especificar que la base que vamos a utilizar es de este tipo

```
source("bspline.R")
fit2=gamm(y~s(x,bs="ps",m=2))
```

en este caso es imprescindible especificar el orden de la penalización **m=2**.

```
plot(x,y)
lines(x,fit$fitted,col=1)
lines(x,fit1$gam$fitted,col=2)
lines(x,fit2$gam$fitted,col=3)
```



La figura muestra como los tres ajustes son casi idénticos.

En el último capítulo veremos como utilizar estas funciones según el tipo de datos que estemos analizando.

Capítulo 3

Aplicaciones

El objetivo de este capítulo es ver como es posible incluir métodos de suavizado con P-splines a los modelos que se utilizan más frecuentemente.

1. Modelos Semiparamétricos

Cuando en un modelo de regresión hay componentes paramétricos y no-paramétricos, tenemos un *modelo semiparamétrico*,

$$\mathbf{y} = \beta_0 + \beta_1 \mathbf{x}_1 + \dots + \beta_{j-1} \mathbf{x}_{j-1} + f(\mathbf{x}_j) + \epsilon$$

La forma de ajustar el modelo es exactamente igual a la que hemos visto anteriormente, simplemente construimos la matriz $\mathbf{X}$ de forma que incluya todas las variables independientes. Sin embargo, hay un caso que merece especial interés y es cuando en la parte paramétrica incluimos un factor con dos o más niveles. Al igual que en el caso de regresión lineal nos podemos plantear si queremos ajustar dos rectas paralelas (modelo aditivo) o no paralelas (modelo con interacción). Además, nos podemos preguntar si la cantidad de suavizado es la misma en el caso de que las curvas no sean paralelas.

Para ilustrar este caso utilizamos los datos que están en el fichero `onions.txt`. Los datos se recogieron en un estudio cuyo objetivo era establecer la relación entre la producción de una planta de cebolla y la densidad de plantas cultivadas. Hay tres variables:

- Densidad (plantas/m²)
- Producción (gramos/planta)
- Localidad

Los datos fueron recogidos por I.S.Rogers (South Australian Dept. of Agriculture & Fisheries).




Figura 1: Gráfico de los datos sobre producción de cebollas en dos localidades, en azul corresponden a Virginia y en verde a Purnong Landing.

La Figura 11 muestra claramente que las cebollas cultivadas en Purnong Landing producen más que las cultivadas en Virginia, es interesante ver si la relación es lineal y en caso de no serlo, si las curvas son paralelas o no. El modelo lineal sería el siguiente:

$$\log(\text{Producción}_i) = \beta_0 + \beta_1 \text{Localidad}_i + \beta_2 \text{Densidad}_i + \epsilon_i$$

donde

$$\text{Localidad}_i = \begin{cases} 0 & \text{si el } i\text{-ésimo dato fue recogido en Purnong Landing} \\ 1 & \text{si el } i\text{-ésimo dato fue recogido en Virginia} \end{cases}$$

La Figura 11 muestra cierta curvatura en cada una de las localidades, lo que sugeriría el modelo:

$$\log(\text{Producción}_i) = \beta_1 \text{Localidad}_i + f(\text{Densidad}_i) + \epsilon_i$$

Para ajustar este modelo el código sería:

```
L=factor(Localidad)
fit1=gamm(log(Produccion)~L+s(Densidad,k=20,m=2))
```

Preguntas:

1. ¿Cuánto se ha reducido el intervalo de confianza para el parámetro de la variable Localidad?
2. ¿Cómo harías el gráfico de las dos curvas que aparecen en la Figura 2?




Figura 2: Gráfico de curvas ajustadas para las dos localidades.

En este caso ambas curvas son paralelas, pero no tenemos por qué asumir este modelo; al igual que en el caso de regresión lineal podemos plantearnos la interacción entre **Localidad** y **Densidad**, es decir, no tenemos por qué suponer que el descenso de la producción cuando aumenta la densidad es el mismo en las dos localidades. En vez de ajustar un modelo *aditivo*, podemos ajustar un modelo con *interacción*:

$$\log(\text{Producción}_i) = f(\text{Densidad}_i)_{L(i)} + \epsilon_i$$

donde

$$L(i) = \begin{cases} 0 & \text{si el } i\text{-ésimo dato fue recogido en Purnong Landing} \\ 1 & \text{si el } i\text{-ésimo dato fue recogido en Virginia} \end{cases}$$

En el contexto de los modelos mixtos, el modelo sería el mismo que aparece en la ecuación (1.6),

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon} \quad \text{pero } \mathbf{Z} = \begin{bmatrix} \mathbf{Z}_0 & \mathbf{0} \\ \mathbf{0} & \mathbf{Z}_1 \end{bmatrix} \quad \mathbf{u} \sim N\left(0, \begin{pmatrix} \sigma_u^2 \mathbf{I} & \mathbf{0} \\ \mathbf{0} & \sigma_u^2 \mathbf{I} \end{pmatrix}\right)$$

Tendríamos efectos aleatorios distintos para cada localidad. El código sería:

```
L.1=factor(1-Localidad)
L.2=L
fit2=gamm(log(Produccion)~L+s(Densidad,k=20,m=2,by=L.1)+s(Densidad,k=20,m=2,by=L.2))
fit2$gam$sp
```

Pregunta:

1. ¿Qué indica el siguiente código?

```
anova(fit1$lme,fit2$lme)
```

Más adelante mostraremos cómo hacer contrastes sobre la necesidad de un modelo con interacción.




Figura 3: Gráfico de curvas ajustadas para las dos localidades utilizando interacción en el modelo (la línea discontinua corresponde a un modelo sin interacción)

Si utilizamos la función `lme()` el código sería:

```
source("MMbasis.R")

#Con B-splines
MM=mixed.model.B(Densidad,min(Densidad)-0.5,max(Densidad)+0.5,20,3,2)

X=MM[[1]]
X=cbind(X,Localidad)
Z=MM[[2]]

n = length(Produccion)
Id = factor(rep(1,n))
#Que Id sea un vector de unos significa que no hay datos anidados
y=log(Produccion)
X = model.matrix(y ~ L*Densidad)
Z.block=list(list(L=pdIdent(~Z-1)))
Z.block=unlist(Z.block,recursive=FALSE)
data.fr = groupedData( y ~ X[,-1] | Id,data = data.frame(y,X,Z))
fit.interac= lme(y~X[,-1],data=data.fr,random=Z.block)
```

`model.matrix(y ~ L*Densidad)` ajusta una ordenada en el origen y una pendiente para cada localidad, y `L=pdIdent( Z-1)` indica dos cosas:

- `L=` indica que la matriz $\mathbf{Z}$ se ha dividido en tantos bloques como niveles tenga el factor `L` (en este caso 2), de modo que si la matriz $\mathbf{Z}$ tiene 20 columnas, tendremos un total de 40 coeficientes aleatorios, 20 para cada localidad.
- `=pdIdent( Z-1)` indica un parametro común para los efectos aleatorios, es decir que la cantidad de suavizado es la misma (aunque las curvas sean diferentes).

En el fichero `onion.R` se muestra cómo ajustar este tipo de modelos.

2. Modelos Aditivos

En esta sección vamos a utilizar datos sobre mortalidad por enfermedades respiratorias relacionadas con la polución. Los datos se encuentran en el fichero `milan.txt` y contiene 5 variables:

- `dia`: Día en el que se tomaron los datos.
- `temp`: Temperatura media diaria.
- `humed`: Humedad relativa.
- `resp.mort`: Muertes por problemas respiratorios.
- `NTP`: Número de partículas suspendidas en el aire.

y buscamos establecer la relación entre las variables meteorológicas y las muertes por cuestiones respiratorias. El modelo que vamos a ajustar es:

$$\sqrt{\text{mort.resp}} = \beta_0 + \beta_1 \text{NTP} + f(\text{dia}) + f(\text{temp}) + f(\text{humed}) + \epsilon$$

de modo que las matrices $\mathbf{X}$ y $\mathbf{Z}$ del modelo mixto serían:

$$\mathbf{X} = \begin{bmatrix} 1 & \text{NTP}_1 & \text{dia}_1 & \text{temp}_1 & \text{humed}_1 \\ 1 & \text{NTP}_2 & \text{dia}_2 & \text{temp}_2 & \text{humed}_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & \text{NTP}_{365} & \text{dia}_{365} & \text{temp}_{365} & \text{humed}_{365} \end{bmatrix} \quad \mathbf{Z} = [\mathbf{Z}_{dia} : \mathbf{Z}_{temp} : \mathbf{Z}_{humed}] \quad \mathbf{u} \sim N \left(0, \begin{pmatrix} \sigma_{dia}^2 \mathbf{I} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \sigma_{temp}^2 \mathbf{I} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \sigma_{humed}^2 \mathbf{I} \end{pmatrix} \right)$$

En R

```
milan=read.table("milan.txt",header=TRUE)
milan=milan[1:365,]
attach(milan)
```

```
y=sqrt(resp.mort)
```

```
x1=NTP
x2=dia
```

```
x3=temp
x4=humed
```

```
library(mgcv)
```

```
fit.aditivo=gamm(y~x1+s(x2,k=20,bs="ps",m=2)+s(x3,k=20,bs="ps",m=2)+
s(x4,k=20,bs="ps",m=2))
```

La ecuación (1.13) nos daba la expresión para el intervalo de confianza de una curva. Ahora necesitamos calcular intervalos de confianza para cada uno de los términos en el modelo aditivo. El I.C. para el término j -ésimo de un modelo aditivo sería:

$$Var[(\hat{f}(\mathbf{x}_j) - f(\mathbf{x}_j))^2] = \hat{\sigma}^2 \mathbf{C}_j (\mathbf{C}'\mathbf{C} + \mathbf{\Lambda})^{-1} \mathbf{C}_j', \quad (3.1)$$

donde $\mathbf{C}_j = \mathbf{C}\mathbf{E}_j$ y $\mathbf{E}_j$ es una matriz diagonal de orden $P \times P$ (donde P es el número de columnas de $\mathbf{C}$) que tiene ceros en la diagonal excepto en los lugares que corresponden al término j -ésimo de un modelo aditivo. Por ejemplo, supongamos que la matriz $\mathbf{Z}_{dia}$ tiene 20 columnas y lo mismo para las otras dos, si quisiéramos calcular un I.C. para la curva ajustada la matriz $\mathbf{E}_j$ tendría ceros en todas las posiciones excepto en $\{1, 3, 6, \dots, 25\}$. En el fichero `aditivo.R` se muestra cómo ajustar el modelo aditivo y calcular las curvas que aparecen en la Figura 4.

De manera similar, podemos calcular los grados de libertad (exactos y aproximados) que




Figura 4: Gráfico de curvas ajustadas para las variables del modelo aditivo, junto con los intervalos de confianza.

corresponden a cada curva:

$$df_j = \text{traza}\{\mathbf{C}_j (\mathbf{C}'\mathbf{C} + \mathbf{\Lambda})^{-1} \mathbf{C}'\} = \text{traza}\{(\mathbf{C}'\mathbf{C} + \mathbf{\Lambda})^{-1} \mathbf{C}'\mathbf{C}_j\}$$

cuando hay más de dos términos en el modelo aditivo, el cálculo de df_j puede ser computacionalmente intenso, por eso en muchas ocasiones se utiliza la siguiente aproximación:

$$adf_j = \text{traza}\{(\tilde{\mathbf{C}}_j' \tilde{\mathbf{C}}_j + \mathbf{\Lambda}_j)^{-1} \tilde{\mathbf{C}}_j' \tilde{\mathbf{C}}_j\}$$

donde $\tilde{\mathbf{C}}_j = [\mathbf{1} : \mathbf{x}_j : \mathbf{Z}_j]$ y $\mathbf{\Lambda}_j = \text{diag}\{0, 0, (\sigma^2/\sigma_{u_j}^2)\mathbf{I}\}$. La aproximación es mejor cuanto menor sea $\sigma^2/\sigma_{u_j}^2$.

3. P-splines para datos longitudinales

Los datos longitudinales son frecuentes en aplicaciones médicas y biológicas. En general, este tipo de datos corresponden a medidas tomadas a varios individuos en distintos instantes de tiempo, y se caracterizan por la dependencia que hay entre las medidas repetidas hechas a un mismo individuo. Los modelos mixtos más sencillos para datos longitudinales representan a cada individuo como la suma de la media de la población (que varía con el tiempo) y que se modela como un efecto fijo, y un polinomio de grado bajo (generalmente una línea) en la que los coeficientes son aleatorios y sirve para modelar la variabilidad individual (Laird and Ware, 1982). Sin embargo, estos modelos pueden no ser apropiados en algunas situaciones, por ejemplo, cuando las trayectorias individuales sean una función no-lineal del tiempo.

Para ilustrar esta metodología vamos a utilizar los datos sobre el estudio de distintas terapias para la leucemia infantil de los que hablamos en la sección 3. Estos datos han sido modificados para preservar la confidencialidad de los mismos y se encuentran en el fichero `leucemia.txt`. El fichero tiene 4 columnas:

- **caso**: Indica a qué niña corresponden los datos
- **tratamiento**: Toma valores 1, 2 o 3 según el tipo de tratamiento que reciben.
- **altura**: Altura en centímetros
- **edad**: Edad en años.

En este ejemplo, tomamos 197 niñas que fueron diagnosticadas de leucemia linfoblástica aguda entre los 2 y los 9 años. La altura de esta niñas se midió en diferentes momentos y en total se recogieron 1988 observaciones. El número de observaciones por niña varía entre 1 y 21.

La Figura 5 muestra la altura de las niñas en función de la edad, podemos ver claramente como cuando llega la pubertad, la relación deja de ser lineal. El código de los modelos que vamos a ajustar se puede encontrar en los ficheros `longitudinal.R` y `longitudinal2.R`.




Figura 5: Altura de las niñas a lo largo del tiempo para cada uno de los tres tratamientos.

3.1. Modelo con ordenada en el origen aleatoria

Este es el modelo más sencillo que podemos proponer para estos datos:

$$y_{ij} = \beta_0 + \beta_1 x_{ij} + \sum_{l=2}^L \gamma_l tr_{il} + U_i + \epsilon_{ij} \quad U_i \sim N(0, \sigma_U^2) \quad \epsilon_{ij} \sim N(0, \sigma_\epsilon) \quad \begin{matrix} 1 \leq i \leq 197 \\ 1 \leq j \leq n_i \end{matrix} \quad (3.2)$$

donde

$$tr_{il} = \begin{cases} 1 & \text{si la niña } i\text{-ésima recibe el tratamiento } l \\ 0 & \text{en otro caso} \end{cases}$$

Este modelo lo que supone es que todas las niñas tiene una tasa de crecimiento lineal e igual para todas, y la variabilidad entre las niñas se tiene en cuenta mediante un efecto aleatorio U_i . En forma matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon}$$

donde

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{T}_1 \\ \vdots & \vdots \\ \mathbf{X}_m & \mathbf{T}_m \end{bmatrix}, \quad \mathbf{X}_i = \begin{bmatrix} 1 & x_{i1} \\ \vdots & \vdots \\ 1 & x_{in_i} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \gamma_1 \\ \gamma_2 \\ \gamma_3 \end{bmatrix}, \quad \mathbf{Z} = \begin{bmatrix} \mathbf{1}_1 & 0 & \dots & 0 \\ 0 & \mathbf{1}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \mathbf{1}_m \end{bmatrix}, \quad \mathbf{1}_i = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}_{n_i \times 1}$$

y $\mathbf{T}_i$ la matriz que indica si la niña i -ésima recibe el tratamiento 1, 2 ó 3.

El código sería:

```
library(nlme)
leucemia=read.table("leucemia.txt",header=TRUE)
attach(leucemia)

modell1 = lme(altura~Xfactor(tratamiento)+edad,random=list(caso=pdIdent(~1)))
```




Figura 6: Rectas ajustadas para las niñas que reciben el radiación hiperfraccionada.

La Figura 16 muestra cómo el modelo (3.2) no explica de forma adecuada la trayectoria individual de las niñas.

3.2. Modelo aditivo mixto

Una extensión natural del modelo anterior sería:

$$y_{ij} = \sum_{l=2}^L \gamma_l tr_{il} + f(x_{ij}) + U_i + \epsilon_{ij} \quad U_i \sim N(0, \sigma_U^2) \quad \epsilon_{ij} \sim N(0, \sigma_\epsilon) \quad (3.3)$$

donde f es una función suave que refleja la tendencia de crecimiento de las niñas. Estimamos f mediante P-splines y utilizamos su representación como modelos mixtos para unificar la estructura del modelo, ahora

$$\mathbf{Z} = \begin{bmatrix} \mathbf{Z}_1 & \mathbf{1}_1 & 0 & \dots & 0 \\ \mathbf{Z}_2 & 0 & \mathbf{1}_2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{Z}_m & \vdots & \vdots & \dots & \mathbf{1}_m \end{bmatrix}, \quad \mathbf{Z}_i = \text{definida en la pag. 13},$$

$$\mathbf{u} = [u_1, \dots, u_K, U_1, \dots, U_m] \quad \text{and} \quad \mathbf{G} = \text{Cov}(\mathbf{u}) = \begin{bmatrix} \sigma_u^2 \mathbf{I} & 0 \\ 0 & \sigma_U^2 \mathbf{I} \end{bmatrix}.$$

En vez de líneas, ajustamos curvas, pero todas son similares, sólo se diferencian en la ordenada en el origen.

En R:

- Utilizando la función `gamm()`:

```
library(mgcv)

fit2.gamm=gamm(altura~factor(tratamiento)+s(edad,k=40,bs="ps",m=2),
               random=list(caso=pdIdent(~1)))
```

- Utilizando la función `lme()`:

```
library(splines)
Id=factor(rep(1,length(altura)))
X=model.matrix(altura~factor(tratamiento)+edad)
#Con B-splines
source("MMbasis.R")
MM=mixed.model.B(edad,min(edad)-0.5,max(edad)+0.5,40,3,2)
Z=MM[[2]]
Z.block2=list(list(Id=pdIdent(~Z-1)),list(caso=pdIdent(~1)))
Z.block2=unlist(Z.block2,recursive=FALSE)
data.fr = groupedData( altura ~ X[,-1] | Id,data = data.frame( altura,X,Z,caso))
model2 = lme(altura~X[,-1],data=data.fr,random=Z.block2)
```

La Figura 7 muestra cómo el modelo (3.3) es demasiado simplista y que asumir que las curvas sean paralelas y con la misma forma no permite explicar las trayectorias individuales de forma correcta.




Figura 7: Curvas ajustadas para las niñas que reciben el radiación convencional.

3.3. Modelo con diferencias individuales lineales

Es una extensión simple del modelo anterior en la cual se asume que las diferencias individuales vienen dadas no sólo mediante la ordenada en el origen, sino también por la pendiente:

$$y_{ij} = \sum_{l=2}^L \gamma_l tr_{il} + f(x_{ij}) + a_{i1} + a_{i2}x_{ij} + \epsilon_{ij} \quad \epsilon_{ij} \sim N(0, \sigma_\epsilon) \quad (a_{i1}, a_{i2})^T \sim N(0, \Sigma) \quad (3.4)$$

que en notación matricial pasa a ser

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon},$$

$$\mathbf{Z} = \begin{bmatrix} \mathbf{Z}_1 & \mathbf{X}_1 & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{Z}_2 & \mathbf{0} & \mathbf{X}_2 & \dots & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{Z}_m & \mathbf{0} & \mathbf{0} & \dots & \mathbf{X}_m \end{bmatrix}, \quad \mathbf{u} = [u_1, \dots, u_K, a_{11}, a_{12}, \dots, a_{m1}, a_{m2}]^T,$$




Figura 8: Curvas ajustadas para las niñas que reciben el radiación convencional, la línea sólida corresponde al modelo con pendiente aleatoria.

$$\mathbf{G} = \text{Cov}(\mathbf{u}) = \begin{bmatrix} \sigma_u^2 \mathbf{I} & 0 \\ 0 & \text{blockdiagonal } \Sigma \\ & 1 \leq i \leq m \end{bmatrix}.$$

En R:

- Utilizando la función `gamm()`:

```
fit3.gamm=gamm(altura~factor(tratamiento)+s(edad,k=40,bs="ps",m=2),
               random=list(caso=pdSymm(~edad)))
```

- Utilizando la función `lme()`:

```
X=model.matrix(altura~factor(tratamiento)+edad)
Z.block3=list(list(Id=pdIdent(~Z-1)),list(caso=pdSymm(~edad)))
Z.block3=unlist(Z.block3,recursive=FALSE)
data.fr = groupedData( altura ~ X[,-1]|Id,data =data.frame(altura,X,Z,caso,edad))
model3 = lme(altura~X[,-1],data=data.fr,random=Z.block3)
```

La Figura 8 muestra cómo el modelo (3.4) permite que las curvas no sólo se muevan en dirección vertical, sino que también oscilen, aún así es posible relajar aún más el modelo.

3.4. Interacción de curva por factor

Uno de los objetivos del estudio llevado a cabo con las niñas que padecían leucemia era comparar los efectos a largo plazo de las tres terapias, de modo que sería interesante ajustar una curva distinta para cada tratamiento. Para hacerlo utilizamos una interacción entre un factor y un predictor continuo, de modo que el modelo (3.4) se puede extender a:

$$y_{ij} = f_{z_i}(x_{ij}) + a_{i1} + a_{i2}x_{ij} + \varepsilon_{ij}$$

$$y_{ij} = \beta_0 + \beta_1 x_{ij} + Z_i u_k \sum_{l=2}^L tr_{il}(\gamma_{0l} + \gamma_{1l}x_{ij}) + \sum_{l=2}^L tr_{il} Z_i w_k^l + a_{i1} + a_{i2}x_{ij} + \varepsilon_{ij} \quad (3.5)$$

$$w_k^l \sim N(0, \sigma_{wl}^2), \quad (a_{i1}, a_{i2})^T \sim N(0, \Sigma) \quad \varepsilon_{ij} \sim N(0, \sigma_\varepsilon^2),$$

donde $tr_{il} = 1$ si $tr_i = l$ y 0 en otro caso.

En un modelo en el que aparecen factores, es necesario imponer alguna restricción para asegurar que el modelo es identificables, en este caso, la restricción que imponemos es: $\gamma_{01} = \gamma_{11} = 0$, lo que significa que $\beta_0 + \beta_1 x_{ij} + Z_i u_k$ es la curva ajustada para $l = 1$, y $\gamma_{0l} + \gamma_{1l}x_{ij} + Z_i w_k^l$ es la diferencia en las curvas ajustadas entre la terapia 2 (radiación convencional) y 3 (radiación hiperfraccionada) y la terapia 1 (no radiación). En R:

- Utilizando la función `gamm()`:

```
T.1=tratamiento;T.1[tratamiento!=1]=0;T.1=factor(T.1)
T.2=tratamiento;T.2[tratamiento!=2]=0;T.2=factor(T.2)
T.3=tratamiento;T.3[tratamiento!=3]=0;T.3=factor(T.3)

fit4.gamm=gamm(altura~factor(tratamiento)+s(edad,k=40,bs="ps",m=2,by=T.1)+
               s(edad,k=40,bs="ps",m=2,by=T.2)+s(edad,k=40,bs="ps",m=2,by=T.3),
               random=list(caso=pdSymm(~edad)))
```

- Utilizando la función `lme()`:

```
X=model.matrix(altura~factor(tratamiento)*edad)
tratamiento=factor(tratamiento)
Z.block4=list(list(tratamiento=pdIdent(~Z-1)),list(caso=pdSymm(~edad)))
Z.block4=unlist(Z.block4,recursive=FALSE)
data.fr = groupedData(altura ~ X[,-1]|Id,data=data.frame(altura,X,Z,case,edad))
model4 = lme(altura~X[,-1],data=data.fr,random=Z.block4)
```

3.5. Curvas específicas para cada individuo

Los modelos más flexibles son aquellos que permiten que las diferencias específicas individuales sean una función no-paramétrica (ver por ejemplo, Ruppert et al. (2003)). Esto es sencillo de hacer mediante los P-splines:

$$y_{ij} = \sum_{l=2}^L \gamma_l tr_{il} + f(x_{ij}) + g_i(x_{ij}) + \epsilon_{ij} \quad \epsilon_{ij} \sim N(0, \sigma_\epsilon)$$




Figura 9: Curvas ajustadas para los distintos tratamientos

$$g(x_{ij}) = a_{i1} + a_{i2}x_{ij} + Z_i v_k \quad (a_{i1}, a_{i2})^T \sim N(0, \Sigma) \quad v_k \sim N(0, \sigma_v^2)$$

Cada curva individual $g_i()$ tiene dos componentes: uno lineal y otro no-paramétrico, pero ambos componentes son aleatorios, a diferencia de lo que hacen otros autores como Brumback and Rice (1998), este nuevo enfoque soluciona los problemas computacionales a los que daba lugar el hecho de tener que estimar $2m$ parámetros para la parte lineal.

Aunque el modelo (3.6) es complejo, se puede describir de forma sencilla en el contexto de los modelos mixtos:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon} \quad \text{with}$$

$$\mathbf{Z} = \begin{bmatrix} \mathbf{Z}_1 & \mathbf{X}_1 & \mathbf{0} & \dots & \mathbf{0} & \mathbf{Z}_1 & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{Z}_2 & \mathbf{0} & \mathbf{X}_2 & \dots & \mathbf{0} & \mathbf{0} & \mathbf{Z}_2 & \dots & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{Z}_m & \mathbf{0} & \mathbf{0} & \dots & \mathbf{X}_m & \mathbf{0} & \mathbf{0} & \dots & \mathbf{Z}_m \end{bmatrix},$$

$$\mathbf{u} = [u_1, \dots, u_K, a_{11}, a_{12}, \dots, a_{m1}, a_{m2}, v_1, \dots, v_K]^T,$$

$$\mathbf{G} = \text{Cov}(\mathbf{u}) = \begin{bmatrix} \sigma_u^2 \mathbf{I} & 0 & 0 \\ 0 & \text{blockdiagonal } \Sigma_{1 \leq i \leq m} & 0 \\ 0 & 0 & \sigma_v^2 \mathbf{I} \end{bmatrix}.$$

En este caso sería muy complejo el uso de la función `gamm()`, ya que tendríamos que definir 197 variables (tantas como niñas) para poder obtener una curva individual para cada niña, sin embargo, esto es bastante sencillo con la función `lme()`:

```
MM.caso=mixed.model.B(edad,min(edad)-0.5,max(edad)+0.5,10,3,2)
tratamiento=factor(tratamiento)
Z.caso=MM.caso[[2]]
Z.block5=list(list(tratamiento=pdIdent(~Z-1)),list(caso=pdSymm(~edad)),
              list(caso=pdIdent(~Z.caso-1)))
Z.block5=unlist(Z.block5,recursive=FALSE)
data.fr=groupedData(altura~X[,-1]|Id,data = data.frame(altura,X,Z,Z.caso,caso,edad))
model5=lme(altura~X[,-1],data=data.fr,random=Z.block5)
```




Figura 10: Curvas estimadas para las medias poblacionales (izquierda) y curvas de contraste con intervalos de confianza (derecha)

Comparación de modelos

Anteriormente, vimos que en el contexto de los modelos mixtos, el método estándar para la estimación de los parámetros de la varianza era REML. Pero además de ser capaces de

estimar los parámetros, nos va a interesar contrastar si necesitamos un modelo paramétrico o no. Realizar este tipo de contrastes no es inmediato. Por ejemplo, en el modelo (3.3), podemos estar interesados en saber si la función que describe la media de la población de niñas es una línea o tiene algún grado de no-linealidad. Esto sería equivalente a contrastar:

$$H_0 : \sigma_u^2 = 0 \quad \text{vs.} \quad H_1 : \sigma_u^2 > 0.$$

El primer problema al que nos enfrentamos es que el parámetro de interés está en la frontera del espacio de parámetros, $[0, \infty)$, por lo que el test de la razón de verosimilitud

$$RLRT = \sup_{H_1} REL(\boldsymbol{\beta}, \sigma_\varepsilon^2, \sigma_U^2, \sigma_u^2) - \sup_{H_0} REL(\boldsymbol{\beta}, \sigma_\varepsilon^2, \sigma_U^2, \sigma_u^2) \quad (3.7)$$

no se puede comparar con una χ_1^2 . Self and Liang (1987) y Stram and Lee (1994) vieron que si $\mathbf{y}$ se puede particionar en subvectores independientes, y el número de subvectores tiende a infinito, (3.7) se distribuye asintóticamente como $\frac{1}{2}\chi_q^2 + \frac{1}{2}\chi_{q+1}^2$, donde q es el número de efectos bajo la hipótesis nula. Sin embargo, esta suposición no es cierta en este tipo de modelos semiparamétricos y en algunos casos esta aproximación puede no ser buena. Crainiceanu et al. (2003b) (Crainiceanu et al. (2002)). Crainiceanu et al. (2003b) derivó el caso en el que se contrasta una regresión polinómica frente a una alternativa modelada mediante P-splines con un único parámetro para la varianza, y Crainiceanu et al. (2003a) estudio el caso en el que hay varios componentes de la varianza. Estos autores también sugieren el uso de simulaciones para determinar la distribución del estadístico del test bajo la hipótesis nula. La idea es la siguiente: se estiman los parámetros del modelo bajo la hipótesis nula, entonces se simula la distribución del test de la razón de verosimilitud bajo la hipótesis nula para esos parámetros. Crainiceanu et al. (2003a) da un método rápido para las simulaciones en algunos casos, sin embargo, la complejidad de estos algoritmos aumenta linealmente con el número de individuos y con la complejidad del modelo, lo que hace que sea computacionalmente inviable.

Vamos a justar dos modelos anidados con 5 y 6 parámetros de la varianza a los datos de leucemia, son los modelos (3.4) y (3.6) pero incluyendo interacción entre curva y factor:

$$y_{ij} = f_{z_i}(x_{ij}) + a_{i1} + a_{i2}x_{ij} + \varepsilon_{ij},$$

$$y_{ij} = f_{z_i}(x_{ij}) + g_i(x_{ij}) + \varepsilon_{ij},$$

donde y_{ij} es la altura de la i -ésima niña a la edad j , para $i = 1, \dots, 197$ y j entre 1 y 21, f_1 es la curva media del grupo de niñas que recibieron terapia intracraal sin radiación, f_2 para las niñas que recibieron radiación convencional y f_3 para niñas que recibieron radiación hiperfraccionada, a_{i1} y a_{i2} las ordenadas en el origen y las pendientes aleatorias, y $g_i(x_{ij})$ es la desviación específica de la i -ésima niña con respecto a la curva media de su grupo.

Nuestro interés en el análisis de estos datos son los efectos de los tratamientos en la altura a lo largo del tiempo y las respuestas individuales al tratamiento.

La Figura 10 muestra las curvas estimadas para la media poblacional de los tres grupos. Se puede apreciar que todos los grupos siguen el mismo patrón, pero la niñas que no recibieron radiación (tratamiento 1) son más altas que las de los otros dos grupos. En particular, este

grupo es significativamente más alto que los demás cuando las niñas llegan a la adolescencia. Para comparar las tres curvas, reajustamos el modelo con una sola curva para la media; la hipótesis nula sería:

$$H_0 : \gamma_{jl} = 0 \quad j = 0, 1 \quad l = 1, 2, 3 \quad \text{and} \quad \sigma_w^2 = 0$$

para γ_{jl} y σ_w^2 definidas en (3.6). Comparamos $-2\log(\text{RLRT})=34.62$ con el percentil 90 de $\frac{1}{2}\chi_2^2 + \frac{1}{2}\chi_3^2$, 5.528. Los resultados son claramente significativos, lo que indica que la altura media de la niñas se ve afectada por la terapia recibida.

El panel derecho de la Figura 10 muestra $\hat{f}_2(x_{ij}) - \hat{f}_1(x_{ij})$ y $\hat{f}_3(x_{ij}) - \hat{f}_1(x_{ij})$ e indica que la altura de las niñas que reciben radiación convencional (terapia 2) es menor, a cualquier edad, que la de la niñas que no reciben radiación (terapia 1).

Para contrastar si la respuesta individual a las terapias es lineal, compararemos los modelos :

$$\begin{aligned} y_{ij} &= f_{z_i}(x_{ij}) + a_{i1} + a_{i2}x_{ij} + \epsilon_{ij} \\ y_{ij} &= f_{z_i}(x_{ij}) + g_i(x_{ij}) + \varepsilon_{ij} \end{aligned}$$

lo que equivale a

$$H_0 : \sigma_v^2 = 0 \quad \text{vs.} \quad H_1 : \sigma_v^2 > 0.$$




Figura 11: Efectos aleatorios estimados para cada niña.

De nuevo, sería preferible utilizar simulaciones, sin embargo, dada la complejidad del modelo comparamos el valor de $-2\log(\text{RLRT})=453.004$, en este caso con el percentil 90 de $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$, 1.642. Los resultados indican claramente que la desviación de cada niña respecto de la media de la población necesita ser explicada de forma no-paramétrica.

La Figura 11 muestra los efectos aleatorios estimados correspondientes a las curvas individuales del modelo (3.6), donde se aprecia que los efectos para algunas niñas son claramente no-lineales.




Figura 12: Gráficos de curvas individuales de 6 niñas (línea continua) con I.C. al 95 % junto con la curva media del grupo (línea discontinua).

La Figura 12 muestra como las curvas medias de las terapias no representan de forma adecuada la altura individual de las niñas, mostrando la pérdida de información que tendríamos sobre las trayectorias individuales si no hubiéramos incluido las curvas individuales en el modelo.

Otra posibilidad es utilizar la función `anova`, aunque no debemos tener en cuenta el p-valor ya que el test es aproximado. Por ejemplo:

```
anova(model4,model5)
```


esta función nos da también el valor del AIC o BIC que podemos utilizar para elegir el modelo.

4. Datos correlados

En esta sección vamos a utilizar los datos que aparecen en Pandit and Wu (1983) y que están en el fichero `madera.txt`, corresponden a 320 medidas tomadas en la superficie de un bloque de madera, las medidas corresponden a la profundidad de las muescas que aparecen en la madera cuando se pule con una piedra circular. La Figura 13 muestra como cambia el tamaño de la muesca con relación al radio de la piedra.

Pandit and Wu (1983) asumieron que la tendencia era *a priori* circular y utilizaron 3




Figura 13: Efecto del lijado en un trozo de madera.

parámetros (dos para el centro y uno para el radio) para ajustarla, e iteraron entre la estimación de esta tendencia y la estructura de los errores. Con el uso de los P-splines es posible flexibilizar la estructura de la tendencia y estimar simultáneamente ambos efectos (algo que es muy difícil si no se utiliza la representación de los P-splines como modelos mixtos). Comenzamos por ajustar un modelo de suavizado, ignorando la estructura de correlación en los datos:

```
cor.gamm=gamm(profundidad~s(distancia, k=40, bs="ps",m=2))
```




Figura 14: Curva ajustada (izquierda) y autocorrelación de los residuos del modelo (derecha).

La Figura 14 muestra como el ignorar la estructura de correlación tiene dos efectos: una curva que no es suave y unos residuos que no son incorrelados. Para solucionar el problema podemos introducir una estructura de autocorrelación en el modelo, por ejemplo un AR(1) y un AR(2).

```
Id=factor(rep(1,320))
cor1.gamm=gamm(profundidad~s(distancia, k=40, bs="ps",m=2),
               correlation=corARMA(form=~distancia|Id,p=1,q=0))
cor2.gamm=gamm(profundidad~s(distancia, k=40, bs="ps",m=2),
               correlation=corARMA(form=~distancia|Id,p=2,q=0))
```

Ahora vemos en la Figura 15, como al asumir un proceso AR(2) para el término de error, es posible separar la correlación a corto plazo y la tendencia global, y no hay restos de correlación en los residuos.

Podemos comparar los modelos ajustados mediante el test de máxima verosimilitud para confirmar que es necesario un modelo AR(2) para el término de error:

```
anova(cor.gamm$lme,cor1.gamm$lme,cor2.gamm$lme)
```

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
cor.gamm\$lme	1	4	1853.437	1868.510	-922.7185			
cor1.gamm\$lme	2	5	1660.112	1678.954	-825.0561	1 vs 2	195.32478	<.0001
cor2.gamm\$lme	3	6	1643.742	1666.352	-815.8711	2 vs 3	18.37015	<.0001




Figura 15: Curva ajustada (izquierda) y autocorrelación de los residuos del modelo con autocorrelación (derecha).

Pregunta:

1. ¿Cuánto vale el parámetro de suavizado en el modelo inicial y en el final? ¿Tiene sentido?

5. Datos multidimensionales

5.1. Ejemplo 1: Tendencias espaciales en experimentos de campo

Las funciones `spm` y `gamm` de las que hablamos en el capítulo anterior, permiten ajustar modelos bidimensionales, sin embargo `spm` asume un mismo parámetro de suavizado en ambas direcciones, lo cual puede dar problemas en algunas situaciones. Vamos a ver cómo se pueden ajustar con R los datos sobre los experimentos de campo llevados a cabo en el Scottish Crop Reserach Institute. En el fichero `SCRI.txt` se encuentran los datos, y en el fichero `SCRI.R` se ajustan, primero un modelo aditivo, y un modelo bidimensional:

```
fit.SCRI=gamm(Produccion~s(Fila,bs="ps",m=2)+s(Columna,bs="ps",m=2))
fit.SCRI2=gamm(Produccion~te(Fila,Columna,bs=c("ps","ps"),m=2))
```

En el caso bidimensional, la especificación del modelo cambia, en este caso utilizamos la función `te()`, que indica que vamos a hacer el producto tensorial de las bases, además `bs=`

será un vector de longitud igual a la dimensión del modelo. Las Figuras 12 y 13 del capítulo anterior muestran las diferencias que hay entre el ajuste de ambos modelos y cómo el modelo aditivo no es apropiado.

```
> anova(fit.SCRI$lme,fit.SCRI2$lme)
```

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
fit.SCRI\$lme	1	6	73.70450	99.67212	-30.852248			
fit.SCRI2\$lme	2	7	20.12908	50.42464	-3.064541	1 vs 2	55.57541	<.0001

Tanto el AIC como el BIC confirman claramente que el modelo bidimensional es más apropiado.

Este tipo de modelos bidimensionales también se pueden ajustar sin necesidad de recurrir la función `gamm()`, simplemente, se calculan las matrices correspondientes al modelo mixto, se programa la función de verosimilitud (REML) y se utiliza la función `optim()` para estimar los parámetros de suavizado, sin embargo, la matriz que corresponde la parte aleatoria del modelo es de dimensiones elevadas (al ser producto de Kronecker de dos matrices), por lo que es necesario utilizar algoritmos que usan la estructura de enrejado de los datos para reducir los cálculos (ver Currie et al. (2006)).

5.2. Ejemplo 2: Análisis de datos de mortalidad

Los datos que vamos a analizar han sido cedidos por el *Continuous Mortality Investigation Bureau* (CMIB) del Reino Unido. Para cada año entre 1947 y 1999 y cada edad (entre 11 y 100 años) se dispone del número de pólizas cobradas (muertes) y del número de pólizas que hay (exposición ó multiplicador de la tasa). Los datos se organizan en matrices $\mathbf{Y}$ y $\mathbf{E}$ cuyas filas están indexadas por edad y las columnas por años, y definimos la mortalidad como: $\mathbf{R} = \mathbf{Y}/\mathbf{E}$. El fichero `mortalidad.txt` contiene los datos, y el código se encuentra en `mortalidad.R`.

```
mortalidad=read.table("mortalidad.txt",header=TRUE)
attach(mortalidad)
library(mgcv)
off=log(exposicion)
```

Como los datos corresponden al número de muertes, estamos en el caso de un modelo lineal generalizado con distribución de Poisson, por lo tanto, estaríamos utilizando los resultados de la sección 4.1; además hemos de tener en cuenta el número de pólizas existentes en ese momento, es decir, buscamos un modelo para la tasa de mortalidad:

$$\log(\mathbf{y}/\mathbf{e}) = f(x, y) \Rightarrow \log(\mathbf{y}) = \underbrace{\log(\mathbf{e})}_{offset} + f(x, y)$$

Nos podemos plantear dos modelos:

- Modelo aditivo suave para Edad-Periodo




Figura 16: Datos sobre mortalidad en el Reino Unido

```
fit=gamm(muertes~s(edad,k=20,bs="ps",m=2)+s(periodo,k=20,bs="ps",m=2)
+offset(off),family="poisson",niterPQL=30)
```

Este modelo ajusta la misma curva para todas las edades y la misma para todos los años. La Figura 17 muestra la superficie (aditiva) a la que da lugar este modelo.

En la Figura 18 se muestra la curva ajustada para el periodo para dos edades distin-




Figura 17: Curvas ajustadas para edad y periodo con un modelo aditivo.

tas, vemos claramente que no es apropiado asumir que el descenso en la mortalidad a lo largo de los años es el mismo para todas las edades. En el caso de los 34 años,

el modelo no es capaz de ajustar correctamente el hecho de que en los últimos años el comportamiento de los jóvenes haya ralentizado el descenso de la mortalidad. En el caso de los 60 años, el modelo tiende a subestimar la mortalidad en los primeros años y a sobrestimarla recientemente.




Figura 18: Curva ajustada periodo con un modelo aditivo para dos grupos de edad.

En las secciones 1 y 2 de este capítulo, vimos como podíamos ajustar los modelos utilizando la función `lme()`, en el caso de datos no Gaussianos, lo equivalente es utilizar la función `glmmPQL()`, cuya estructura es similar a la anterior, en este caso la estimación de los parámetros está basada en *Penalized Quasi-Likelihood*. En el fichero `mortalidad2.R` se encuentra el código que ajusta el modelo anterior mediante esta función.

■ Modelo de suavizado bidimensional

```
fit2=gamm(muertes~te(edad,periodo,k=c(10,10),bs=c("ps","ps"),m=2)
         +offset(off) ,family="poisson",niterPQL=30)
```




Figura 19: Curva ajustada periodo con un modelo bidimensional para dos grupos de edad.

La Figura 19, muestra la superficie ajustada en este caso, se pueden apreciar las diferencias sobre todo en las edades tempranas y en los ancianos. En la Figura 20 vemos como ahora el modelo ajusta correctamente las curvas para las distintas edades.




Figura 20: Curva ajustada con un modelo bidimensional para dos grupos de edad.

Por último, la Figura 21 nos da una idea sobre el ajuste del modelo. La figura de la izquierda muestra la relación entre el número de muertes y los valores ajustados, y la figura de la derecha muestra el gráfico de los valores ajustados frente a los residuos de

Pearson: vemos como hay unos cuantos residuos elevados que corresponden a valores predichos próximos a cero, pero en general el ajuste es bastante bueno.




Figura 21: Gráficos de valores ajustados y residuos.

5.3. Ejemplo 3: Aplicaciones en disease mapping

Los datos corresponden al número observado y esperado de casos de cáncer de labio registrado en 54 municipios de Escocia, junto con la proporción de la población que trabaja en agricultura, bosques y pesca. Estos datos han sido analizados utilizando diversos enfoques, generalmente basados en modelos espaciales jerárquicos donde los efectos aleatorios asociados a cada municipio están modelizados mediante diferentes distribuciones a priori (modelos autoregresivos condicionales).

Nuestra propuesta es utilizar, no el hecho de que los municipios sean vecinos, sino las coordenadas de los centroides de cada municipio para modelizar el efecto espacial y además añadir un efecto aleatorio para cada municipio con el objetivo de controlar la posible sobre-dispersión de los datos.

En este caso, los datos no están en un enrejado, por lo que la base de b-splines no es el producto de Kronecker de las bases en cada dimensión sino llamado *producto de Kronecker por filas*: $\mathbf{B} = \mathbf{B}_2 \square \mathbf{B}_1$, donde cada fila de la matriz $\mathbf{B}$ es el producto de Kronecker de las filas correspondientes de las bases individuales. Utilizamos nuevamente los resultados de la sección 4 y utilizamos la representación de los Psplines como modelos mixtos:

$$\boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha} \quad \boldsymbol{\alpha} \sim \mathcal{N}(\mathbf{0}, \mathbf{G})$$

Para modelizar la posible sobredispersión de los datos y tener en cuenta la posibilidad de que una superficie suave no capture la variabilidad de los datos, añadimos un efecto aleatorio para cada municipio, por tanto el modelo sería:

$$\mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha} + \boldsymbol{\gamma} \mathbf{I} \quad \boldsymbol{\alpha} \sim \mathcal{N}(\mathbf{0}, \mathbf{G}), \quad \boldsymbol{\gamma} \sim \mathcal{N}(0, \sigma_\gamma^2 \mathbf{I})$$

Este modelo recibe el nombre de PRIDE (“*Penalized Random Individual Dispersion Effects*”).

Los datos se encuentran en el fichero `lipcancer.txt` y el código en `lipcancer.R`. Se han ajustado dos modelos, sin efectos aleatorios individuales y otro con efectos aleatorios:

```
fit.lip=gamm(y~AFF+te(lat,lon,bs=c("ps","ps"),k=c(6,8),m=2)+offset(off),
            family="poisson")
```

```
fit.lip2=gamm(y~AFF+te(lat,lon,bs=c("ps","ps"),m=2)+offset(off),
            random=list(dist=~1),family="poisson")
```

Para comparar ambos modelos vamos a utilizar el AIC:

$$AIC = Dev + 2Df \quad Dev = \sum_i y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i)$$

```
y.new=y
y.new[y==0]=10^-4
ajustados=fit.lip$lme$fitted
ajustados=ajustados[,2]
mu=exp(ajustados)*exp(off)
Dev=sum(2*y.new*log(y.new/mu)-(y.new-mu))
Df=sum(fit.lip$gam$edf)
AIC=Dev+2*Df
```

El valor de AIC es 98.68 en el modelos sin efectos aleatorios individuales y 40.64 en el modelo con efectos aleatorios para cada municipio y el valor de $\sigma_\gamma^2 = 0,125$.




Figura 22: Ajuste de los dos modelos propuestos (en la escala del predictor lineal)

En la Figura 22 vemos la diferencia entre el ajuste, sin y con los efectos aleatorios individuales, la introducción de estos efectos permiten tener en cuenta las características individuales de cada municipio; estas características pueden ser bastantes distintas a las de sus municipios vecinos, y por tanto no se captarían en un modelo donde sólo hubiera suavizado.

Bibliografía

- Breslow, N. and Clayton, D. (1993). Approximate inference in generalized linear mixed models. *Journal of the American Statistical Association*, 88:9–25.
- Brezger, A., Kneib, T., and Lang, S. (2005). Bayesx: Analysing bayesian structured additive regression models. *Journal of Statistical Software*, 14(11).
- Brumback, B. and Rice, J. (1998). Smoothing spline models for the analysis of nested and crossed samples of curves. *Journal of the American Statistical Association*, 93:961–994.
- Coull, B., Schwartz, J., and Wand, M. (2001). Respiratory health and air pollution: Additive mixed model analyses. *Biostatistics*, 2:337–349.
- Crainiceanu, C., Ruppert, D., Claeskens, G., and Wand, M. (2003a). Likelihood ratio test of polynomial regression against a general non-parametric alternative. *submitted*.
- Crainiceanu, C., Ruppert, D., and Vogelsang, T. (2002). Probability that the mle of a variance component is zero with applications to likelihood ratio tests. *submitted*.
- Crainiceanu, C. M., Ruppert, D., Claeskens, G., and Wand, M. (2003b). Likelihood ratio test of polynomial regression against a general nonparametric alternative. *submitted*.
- Currie, I., Durbán, M., and Eilers, P. (2004). Smoothing and forecasting mortality rates. *Statistical Modelling (en prensa)*.
- Currie, I., Durbán, M., and Eilers, P. (2006). Generalized linear array models with applications to multidimensional smoothing. *Journal of the Royal Statistical Society, Series B*, 68:1–22.
- De Boor, C. (1977). Package for calculating with B-splines. *Journal of Numerical Analysis*, 14:441–472.
- De Boor, C. (2001). *A practical guide to splines*. Applied Mathematical Sciences. Springer-Verlag, New York.
- Dierckx, P. (1993). *Curve and surface fitting with splines*. Clarendon, Oxford.
- Durbán, M., Currie, I., and Eilers, P. (2002). Using P -splines to smooth two-dimensional Poisson data. In Stasinopoulos, M. and Touloumi, G., editors, *Proceedings of the 17th International Workshop on Statistical Modelling*, pages 207–214, Crete, Greece.

- Eilers, P. and Marx, B. (1996). Flexible smoothing with B -splines and penalties. *Statistical Science*, 11:89–121.
- Green, P. and Silverman, B. (1994). *Nonparametric Regression and Generalized Linear Models*. Monographs on Statistics and Applied Probability. Chapman & Hall, London.
- Hastie, T. and Tibshirani, R. (1986). Generalized additive models. *Statistical Science*, 1:297–318.
- Hastie, T. and Tibshirani, R. (1987). Generalized additive models: Some applications. *Journal of the American Statistical Association*, 82:371–386.
- Kneib, T. (2005). *Mixed Model Based Inference in Structured Additive Regression*. PhD thesis, Department of Statistics, Ludwig-Maximilians University, Munich.
- Laird, N. and Ware, J. (1982). Random-effects models for longitudinal data. *Biometrics*, 38:963–974.
- Lang, S. and Brezger, A. (2004). Bayesian p -splines. *Journal of Computational and Graphical Statistics*, 13.
- Marx, B. and Eilers, P. (1998). Direct generalized additive modeling with penalized likelihood. *Computational Statistics and Data Analysis*, 28:193–209.
- Ngo, L. and Wand, M. (2004). Smoothing with mixed model software. *Journal of Statistical Software*, 9(1).
- Nychka, D. (1988). Confidence intervals for smoothinf splines. *Journal of the American Statistical Association*, 83:1134–43.
- O’Sullivan, F. (1986). A statistical perspective on ill-posed inverse problems. *Statistical Sciences*, 1:505–527.
- Pandit, S. and Wu, S.-M. (1983). *Time series and system analysis with applications*. Wiley, New York.
- Parise, H., Ruppert, D., Ryan, L., and Wand, M. (2001). Incorporation of historical controls using semiparametric mixed models. *Journal of the Royal Statistical Society, C*, 50:31–42.
- Rice, J. and Wu, C. O. (2001). Nonparametric mixed effects models for unequally sampled noisy curves. *Biometrics*, 57:253–259.
- Ruppert, D. (2002). Selecting the number of knots for penalized splines. *Journal of computational and Graphical Statistics*, 11:735–757.
- Ruppert, D., Wand, M., and Carroll, R. (2003). *Semiparametric Regression*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press.
- Self, S. and Liang, K. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82:605–610.

- Speed, T. (1991). Comment on "BLUP is a good thing: The estimation of random effects", by robinson, g.k. *Statistical Science*, 6:15–51.
- Stram, D. and Lee, J. (1994). Variance components testing in the longitudinal mixed effects model. *Biometrics*, 50:1171–1177.
- Verbyla, A., Cullis, B., Kenward, M., and Welham, S. (1999). The analysis of designed experiments and longitudinal data using smoothing splines. *Applied Statistics*, 48:269–312.
- Wahba, G. (1983). Bayesian confidence intervals"for the cross-validated smoothing spline. *J. Roy. Stat. Soc. B*, 45:133–150.
- Wand, M. (2003). Smoothing and mixed models. *Computational Statistics*, 18:223–249.
- Wood, N. (2003). Thin plate splines regression. *Journal of the Royal Statistical Society*, 65(1):95–114.
- Wood, S. (2006). mgcv 1.3. r package. cran.r-project.org.
- Wood, S. (2007). On confidence intervals for gams based on penalized regression splines. *submitted*.